STRIPE PROJECT

8. Global Data Architecture

D1. Data Architecture Diagrams

> *Nicolas Pichon - AIA RNCP 38777 / BC02 / D1 : Data Architecture Diagrams / v33 - 2026/11/05.*

D1.1. Introduction

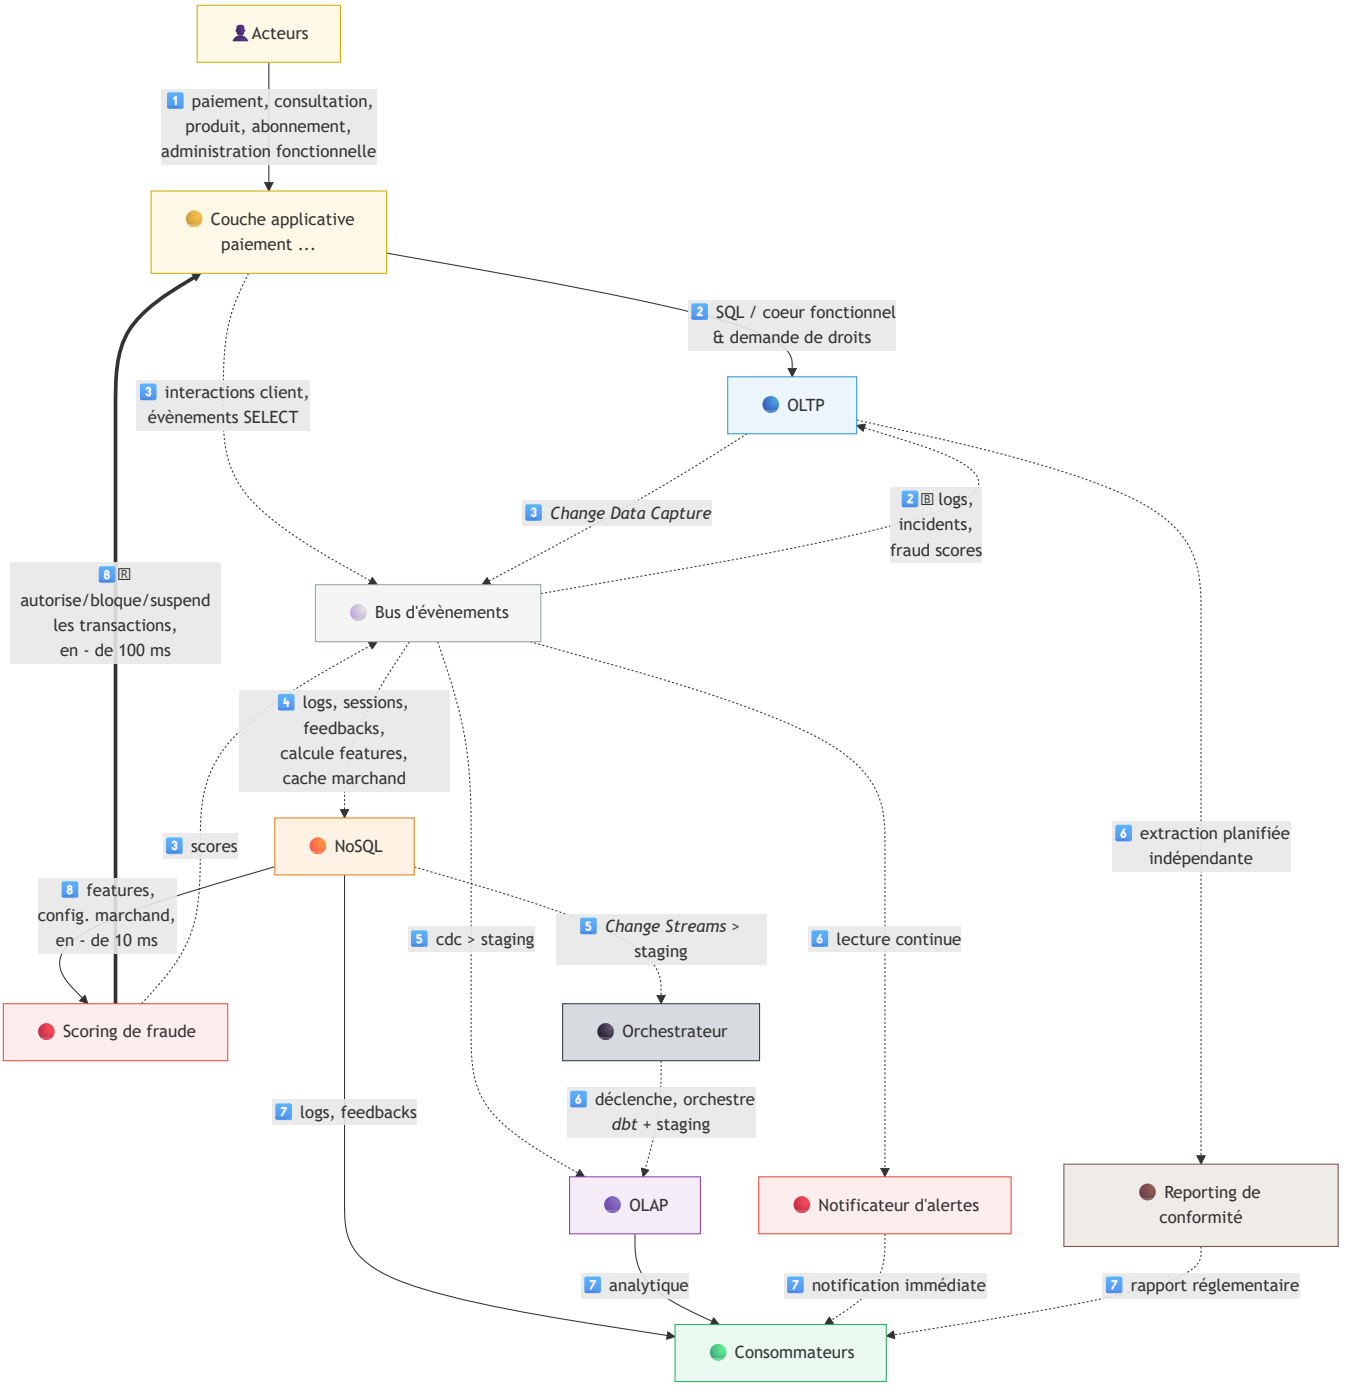
D1.1.1. Contexte

Ce document présente l'architecture de données du projet *Stripe* [D0]. Il décrit l'intégration des systèmes *OLTP* [D2], *OLAP* [D3] et *NoSQL* [D4], et détaille les flux de données et les pipelines qui lient ces systèmes.

L'architecture est structurée par les principes suivants :

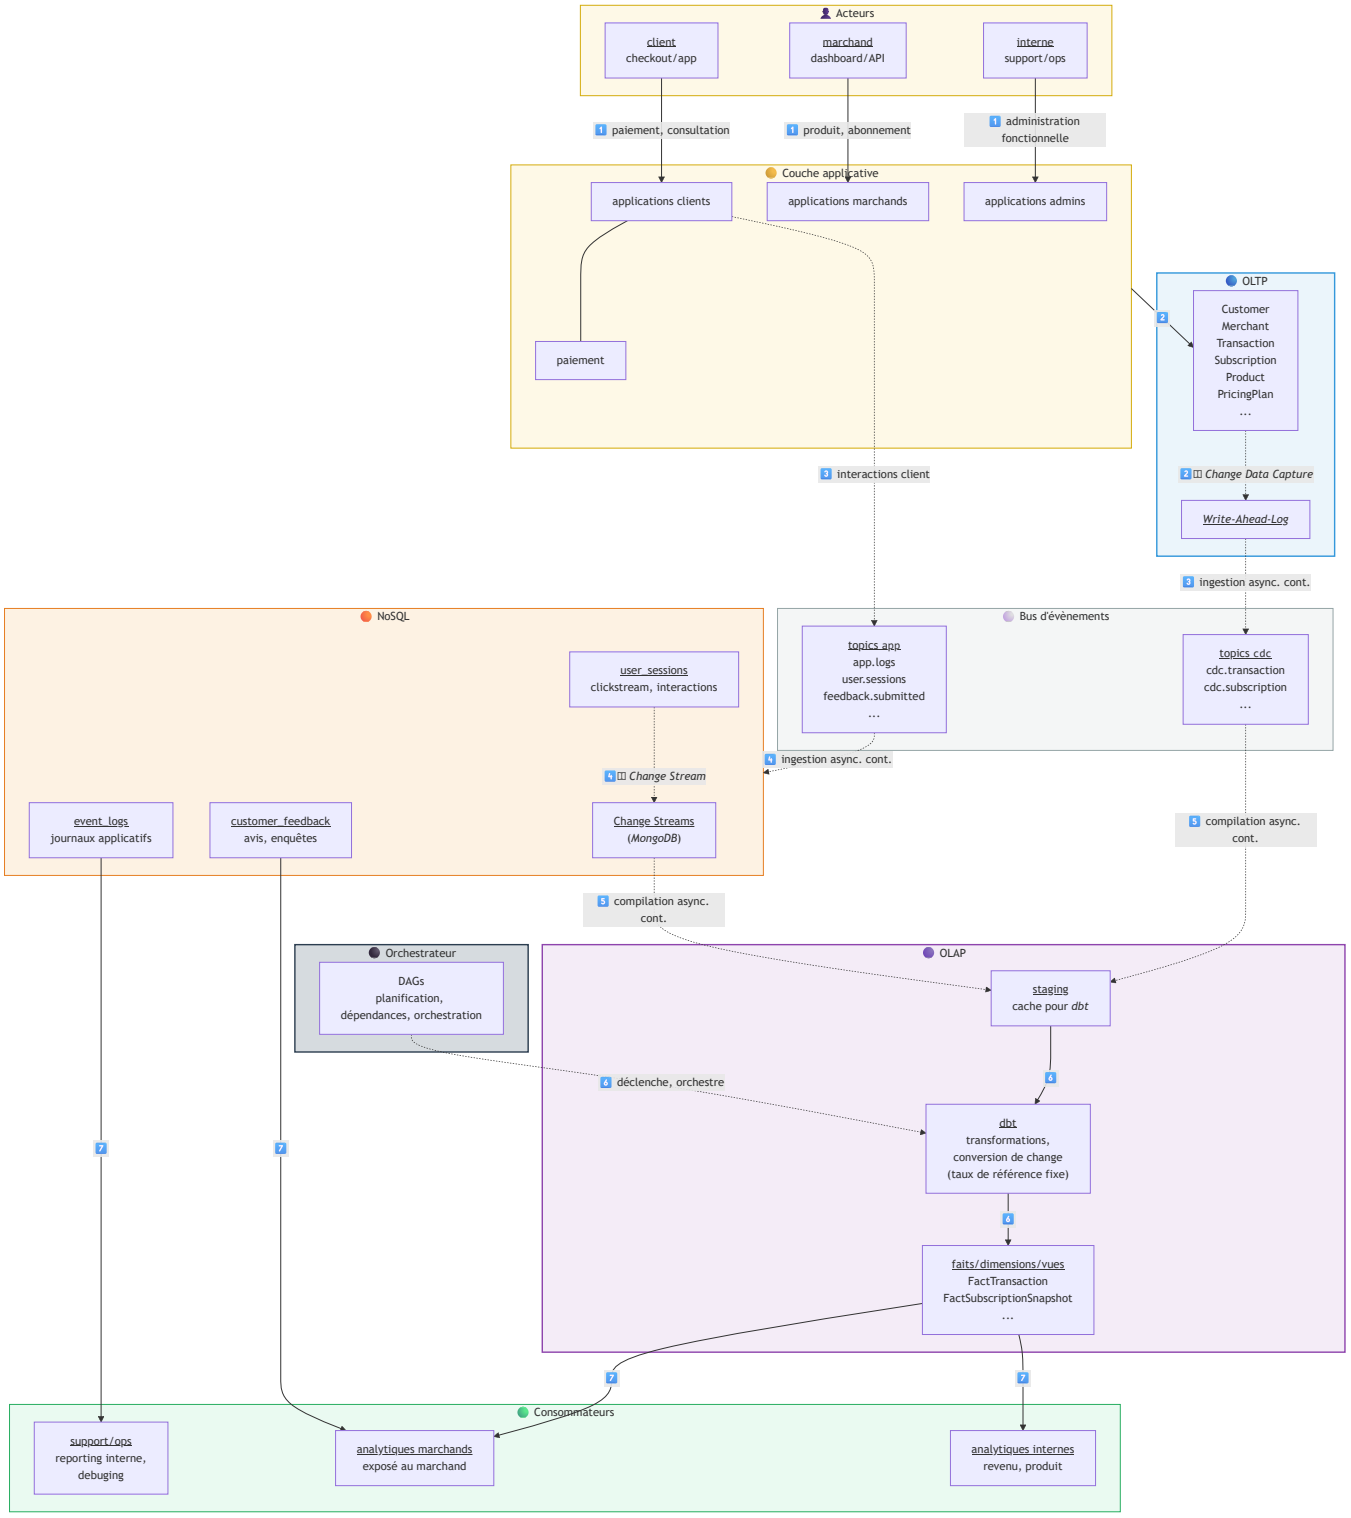
1. *Le chemin transactionnel ne doit jamais être ralenti* par des processus de sécurité, de conformité, d'analytique ou de détection de fraude. Les flux de données qui partent du système transactionnel vers les autres systèmes de données sont donc *asynchrones*.
2. *La réplication des changements d'état transactionnels ne doit pas être synchrone*. On évite les déclencheurs synchrones (*triggers*) et on privilégie l'exploitation asynchrone du flux *CDC* (*Change Data Capture*) natif du système *OLTP*.
3. *Le taux de change est fixe* dans la base analytique. Il est actualisable périodiquement (annuellement par exemple).

D1.2. Vue d'ensemble

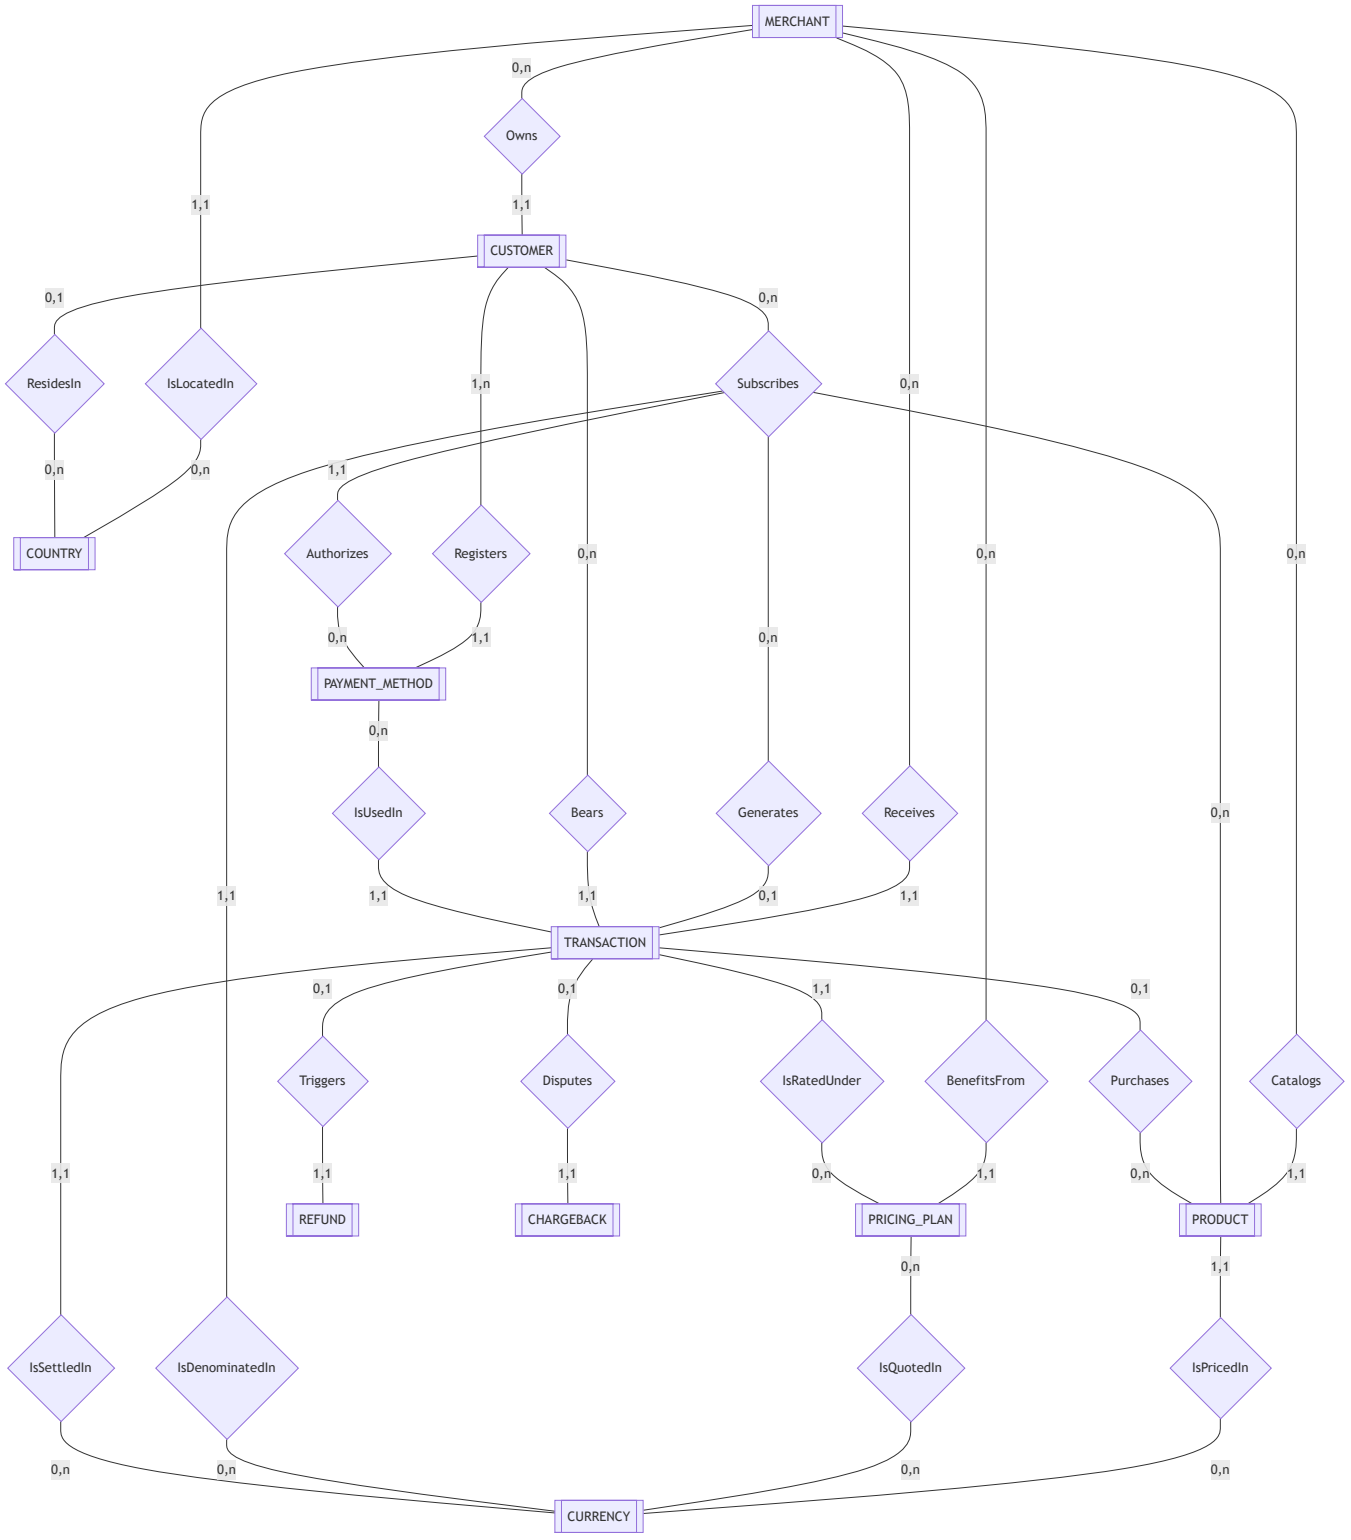


D1.3. Vue du coeur métier

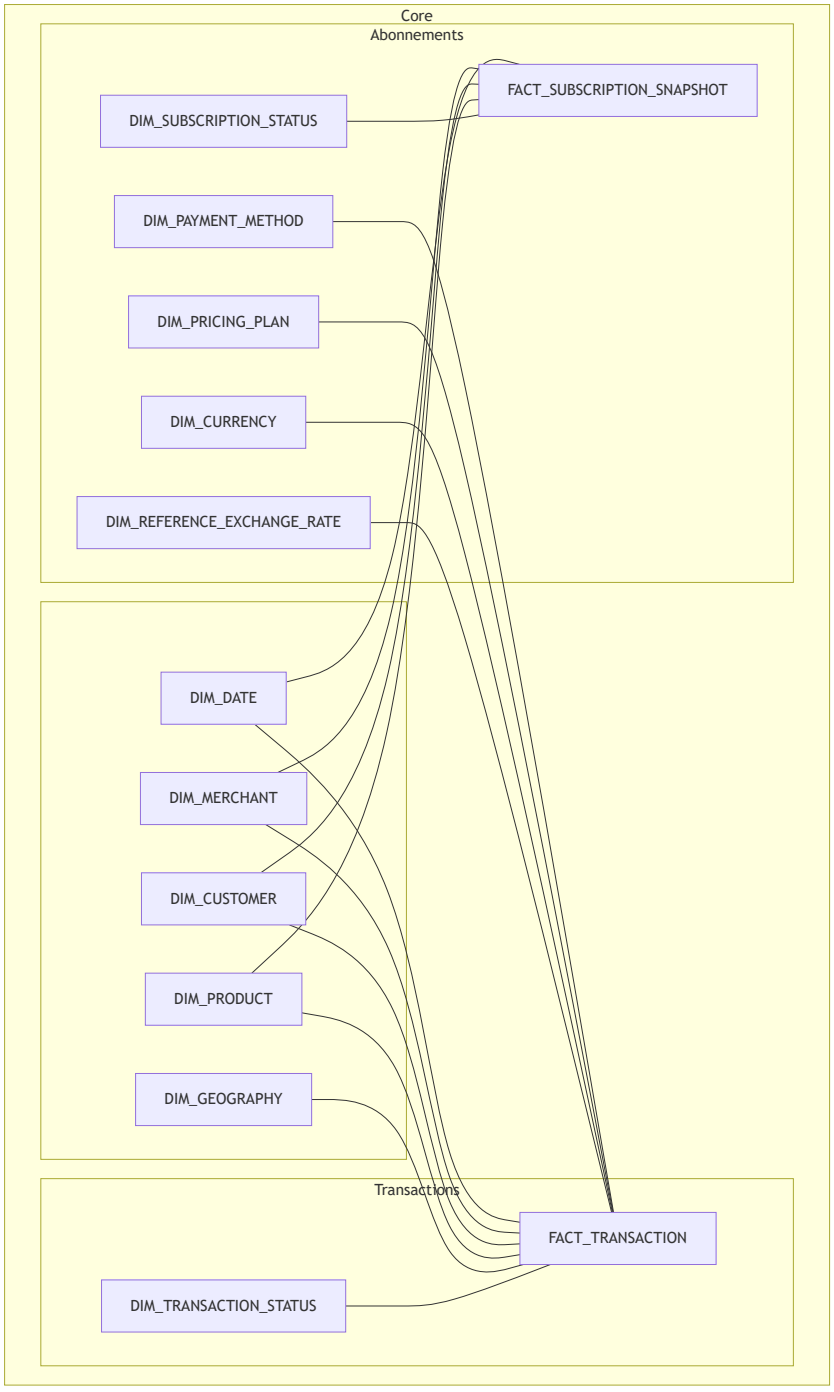
D1.3.1. Architecture



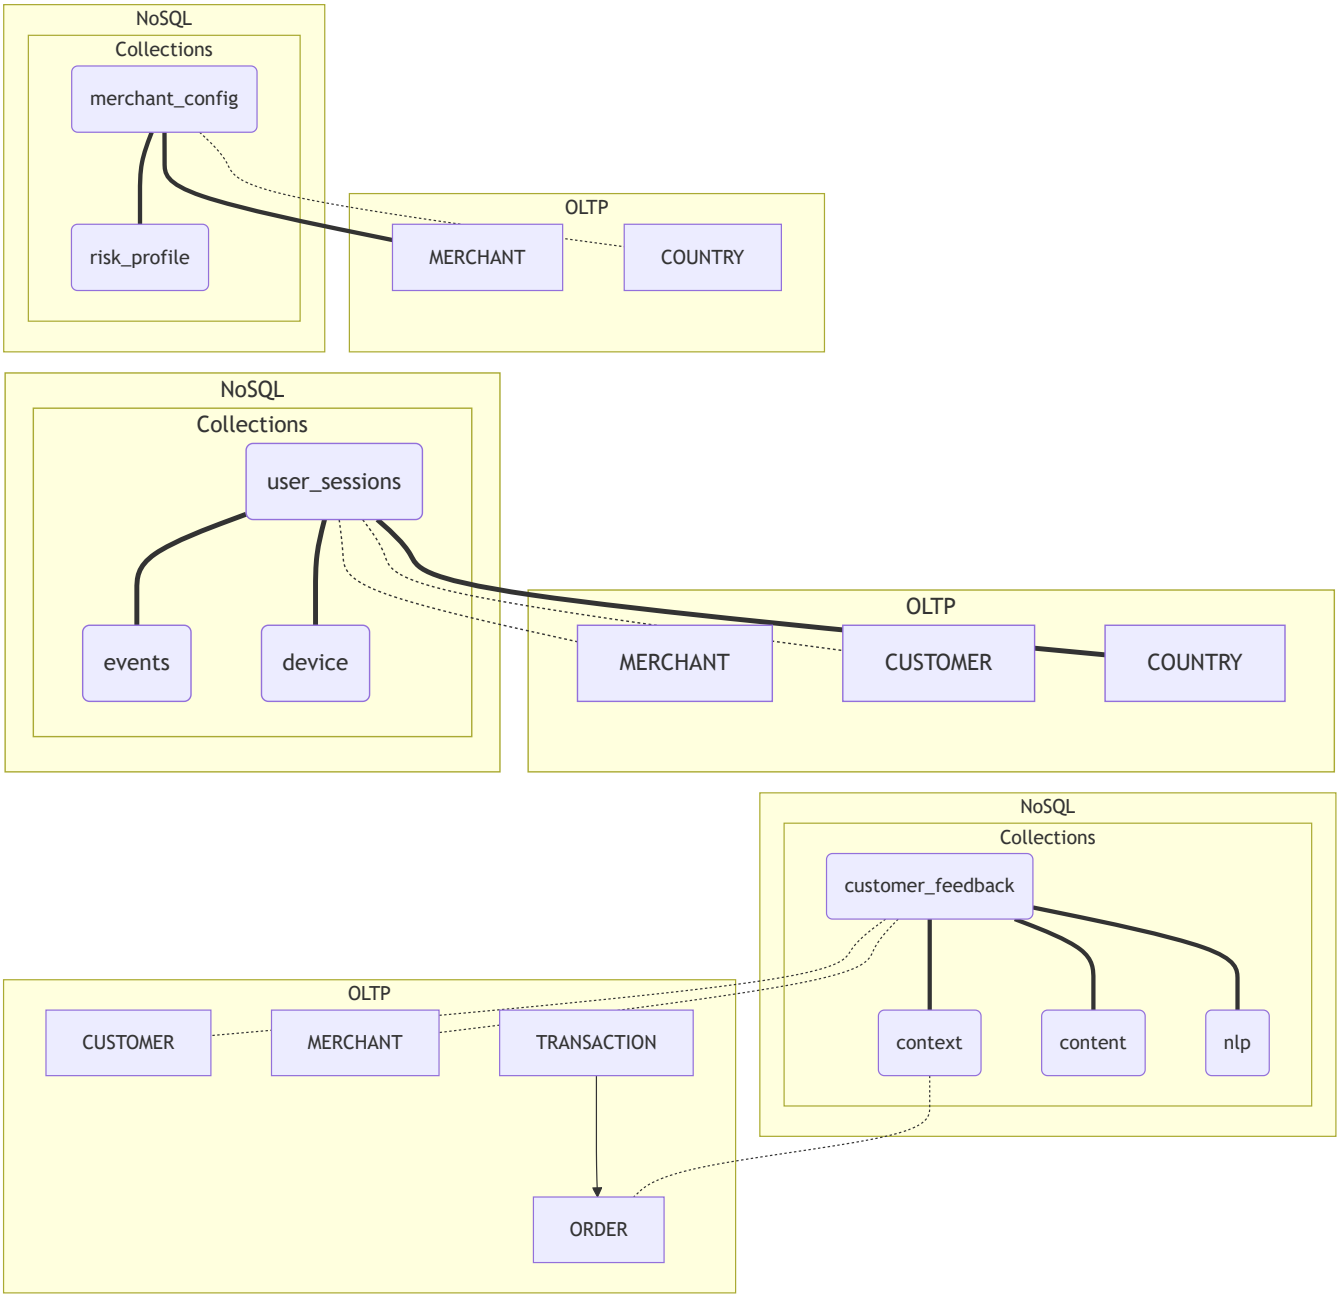
D1.3.2. Modèle de données transactionnelles



D1.3.3. Modèle de données analytiques



D1.3.4. Modèle de données non-structurées



D1.3.5. Flux de données

#	Flux	Mécanisme	Justification
1	Acteurs → Apps	écr. sync. directe	Flux d'entrée des données dans le système ; passe par une couche applicative interne qui isole le système les acteurs externes sont : client/marchand/interne.
2	Apps → Core OLTP	écr. sync. directe	Logique de traitement (validation, orchestration du paiement) séparée de la logique de persistance.
3	Core OLTP → Topic `cdc`	lect. async. cont. du *WAL*	Journalisation des modifications des tables Core (`Transaction` , etc.) => *banir les déclencheur synchrone (triggers*) => lecture *asynchrone* du journal système (WAL : Write-Ahead-Log) + publication des modifications dans les topics `cdc` .
4	Topic `app` → NoSQL	ingest. async. cont.	Transport des logs d'application, clickstreams, interactions avec l'utilisateur, vers NoSQL.
5	Topic `cdc` → staging OLAP	extract. async. cont.	Chargement temporaire des modifications des tables Core (via les les topics `cdc`) dans l'entrepôt OLAP
5	NoSQL *Change Streams* → staging OLAP	extract. async. cont.	Chargement temporaire des modifications de la collection NoSQL `user_sessions` dans l'entrepôt OLAP
6	dbt + staging → OLAP Core	transf. plan.	L'orchestrateur déclenche les processus de transformation (ici, portés par *dbt*), les processus transforment et chargent directement dans l'entrepôt OLAP ;
7	OLAP Core → analytiques	req. analytiques	1 consommateur externe : marchand, 1 consommateur interne : analyste revenus & produits
7	NoSQL `customer_feedback` → marchand	req. analytiques	1 consommateur externe : marchand
7	NoSQL `event_logs` → admins	req. analytiques	1 consommateur interne : administrateur fonctionnel

> *abréviations :*
>
> - écr. = écriture
> - lect. = lecture
> - cont. = continue
> - sync. = synchrone
> - async. = asynchrone
> - ingest. = ingestion
> - compil. = compilation
> - extract. = extraction
> - transf. = transformation
> - plan. = planifié
> - req. = requêtes

D1.4. Vue du scoring de fraude

D1.4.1. Architecture

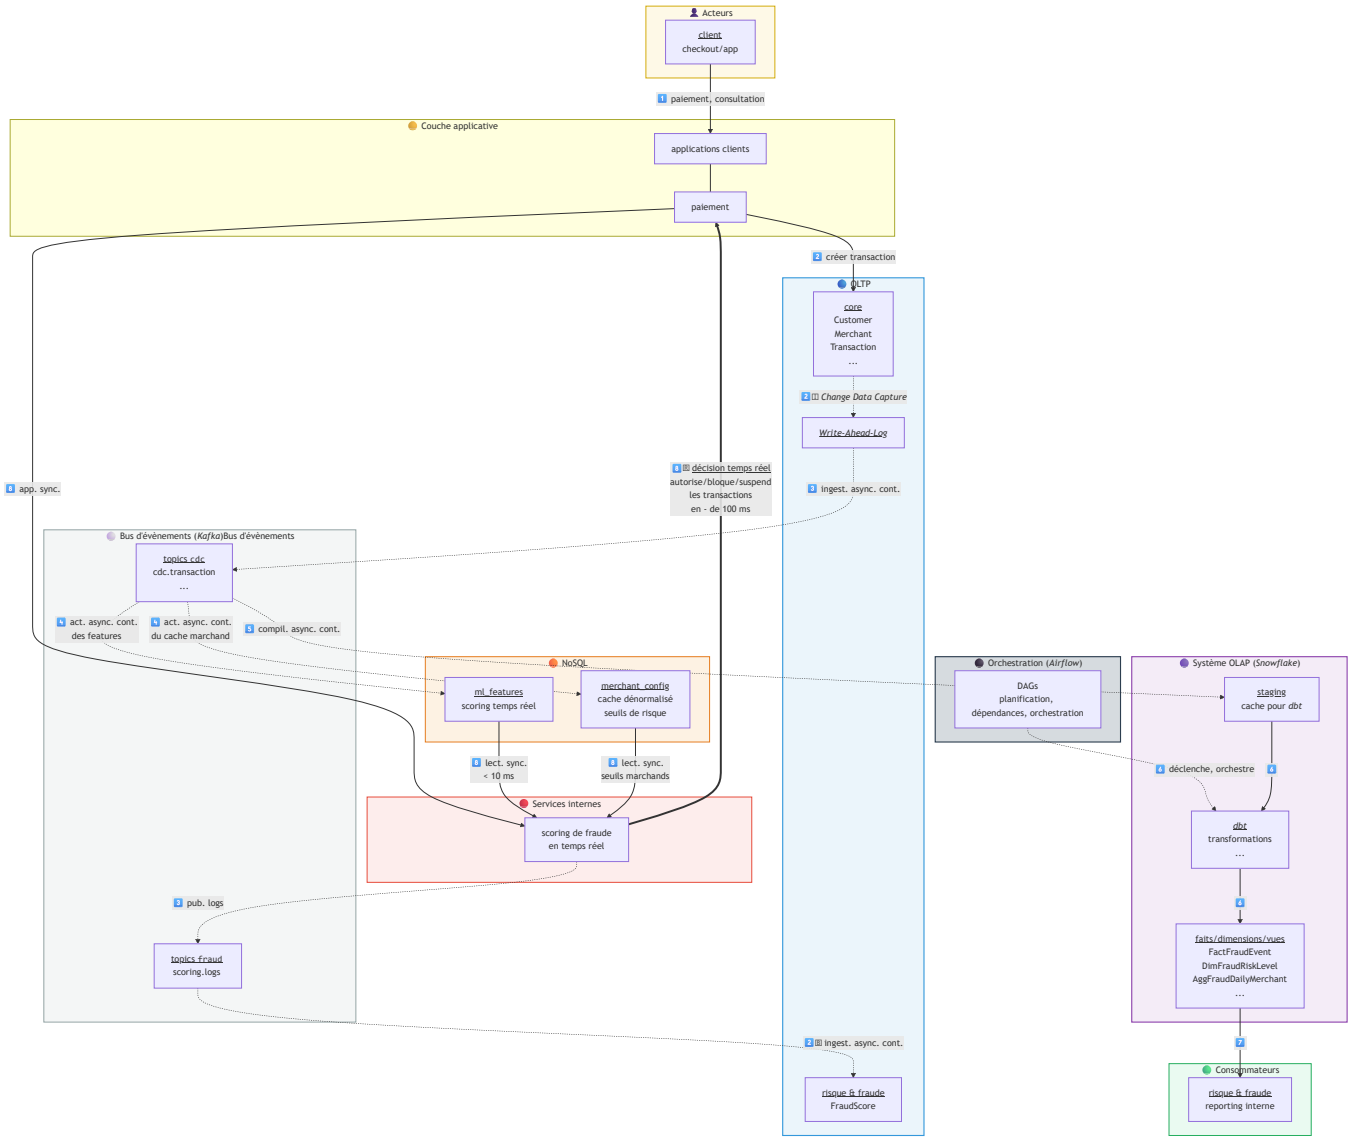
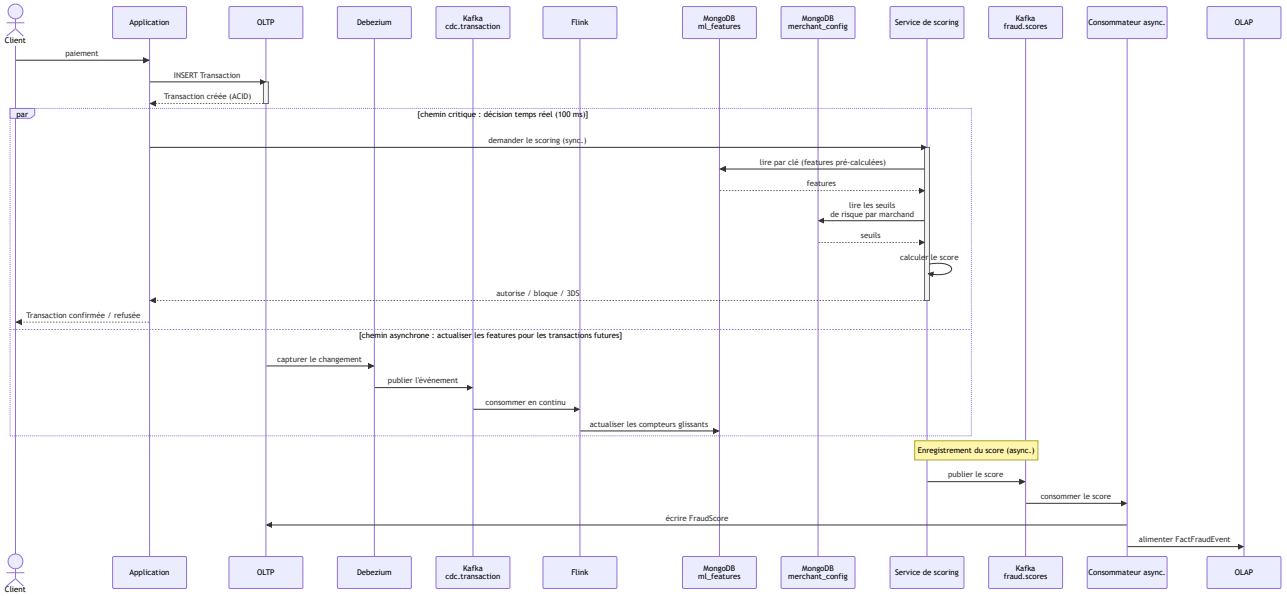
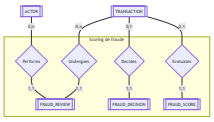


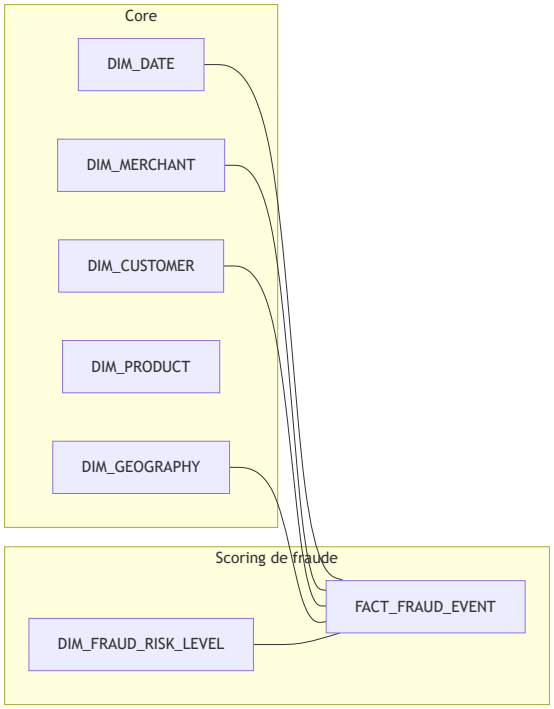
Diagramme de séquence du scoring de fraude au cours d'une transaction



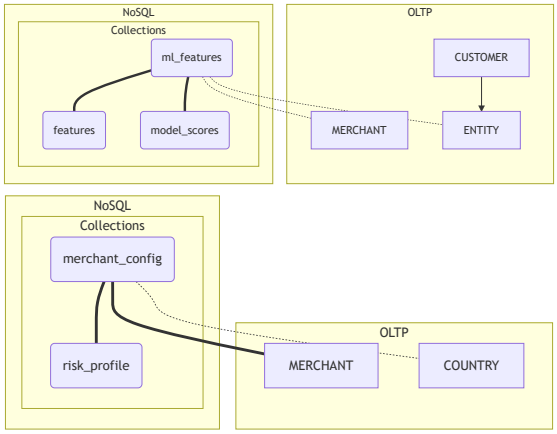
D1.4.2. Modèle de données transactionnelles



D1.4.3. Modèle de données analytiques



D1.3.4. Modèle de données non-structurées



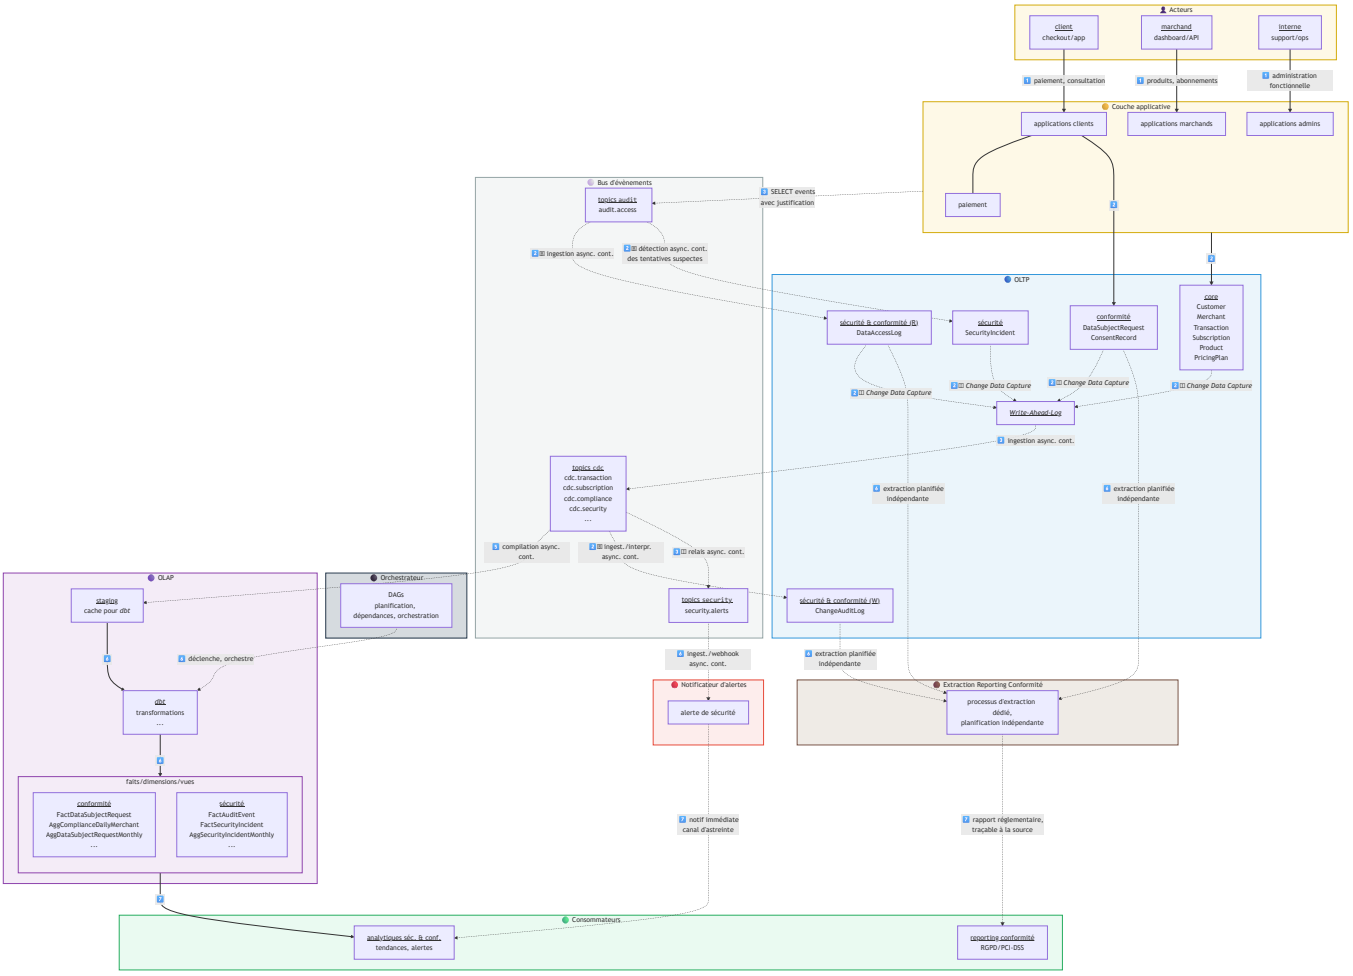
D1.4.5. Flux de données

#	Flux	Mécanisme	Justification
4	Topic `cdc` → NoSQL `merchants`	act. async. cont. du cache marchands	Cache dénormalisé actualisé à chaque changement de OLTP Core ; évite d'interroger OLTP à chaque événement app
4	Topic `cdc` → NoSQL `features`	act. async. cont. des features	Le recalcul des features suit le même flux CDC que "NoSQL merchants" ; pas de mécanisme distinct
8	NoSQL `features` → scoring	lect. sync. < 10 ms	Alimente le modèle de fraude en continu
8	NoSQL `merchants` → scoring	lect. sync.	Seuils de risque par marchand, consultés en même temps que les features
8R	scoring → Apps	rép. sync.	Autorise/bloque/suspend la transaction ; latence bout en bout < 100 ms ; la décision revient à la couche applicative ; la persistance du score est un flux séparé
3	scoring → Topic `fraud`	pub. async.	Seul flux qui revient vers OLTP par un mécanisme asynchrone ([D5] §D5.5.4), distinct de la décision de fraude elle-même
2B	Topic `fraud` → OLTP `FraudScore`	...	Enregistre le score dans OLTP ; planifié/compilé/orchestré ?
5	Topic `fraud` → staging OLAP	extract. async. cont.	cf. §D1.3.5.
5	NoSQL → staging OLAP	transf. plan.	cf. §D1.3.5.
6	`dbt` + staging → OLAP	transf. planifiée	Alimente `FactFraudEvent` via `dbt`
7	OLAP → analytiques	req. analytiques	Découplé du chemin transactionnel, pas d'impact sur latence de paiement, quatre consommateurs analytiques distincts, tous alimentés par OLAP ([D1] §D1.2) : 1 externe: marchand, 3 internes: revenu & produit, risque & fraude, sécurité & conformité

> *abréviations :*
>
> - act. = actualisation
> - pub. = publication
> - lect. = lecture
> - écr. = écriture
> - cont. = continue
> - sync. = synchrone
> - async. = asynchrone
> - transf. = transformation
> - req. = requêtes
> - rép. = réponse

D1.5. Vue du reporting de sécurité et de conformité

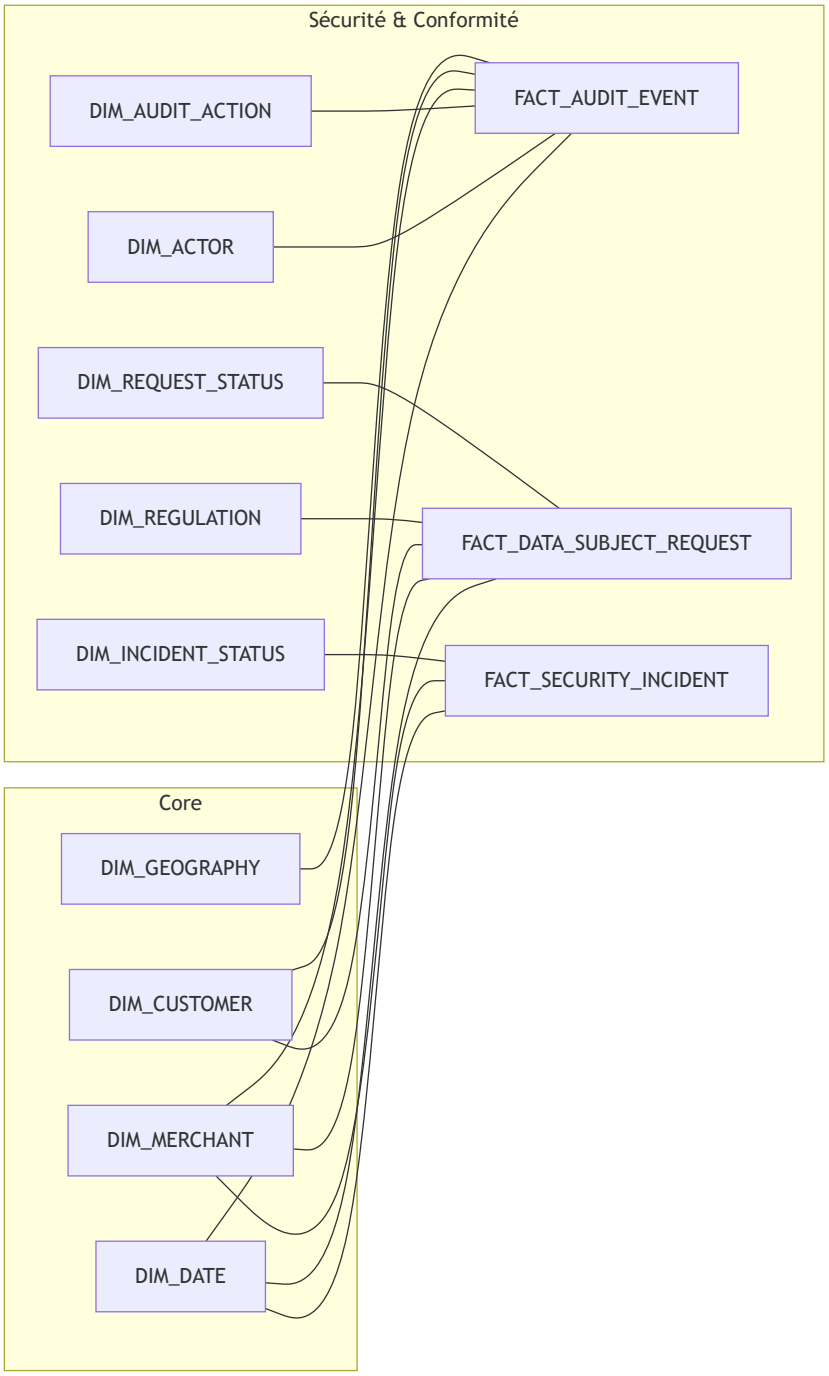
D1.5.1. Architecture



D1.5.2. Modèle de données transactionnelles

“diagrams/stripe-project--d1-data-architecture--diagram-4-3--transactional-model-3--v25.svg” n'a pas été trouvée.

D1.5.3. Modèle de données analytiques



D1.5.5. Flux de données

#	Flux	Mécanisme	Justification
3	Apps → Topic `audit`	pub. async. d'événement justifié	`SELECT` ne laisse pas de trace dans *WAL* ; l'application connaît le contexte de l'accès
2B	Topic `audit` → OLTP `DataAccessLog`	ingest. async. cont.	Mappage direct : la justification de l'accès voyage dans le message publié par Apps
3	OLTP `DataAccessLog` → Topic `cdc`	lect. async. cont. du *WAL*	Réplication standard
	OLTP Sécurité → Topic `cdc`		
	OLTP Conformité → Topic `cdc`		
2B	Topic `cdc` → OLTP `ChangeAuditLog`	ingest. async. cont.	Dérive une ligne d'audit depuis l'événement CDC ; *`ChangeAuditLog` ne doit pas être recapturée par CDC*
2B	Topic `audit` → OLTP `SecurityIncident`	détect. async. cont.	Détection à état (fenêtres glissantes)
3i	Topic `cdc` → Topic `security`	relais async. cont.	Réutilise le fait constaté (l'écriture de `SecurityIncident`) plutôt que de redétecter une seconde fois depuis `audit.access`
6+7	Topic `security` → équipe sécurité	...	Le mécanisme de notification (canal d'astreinte) reste indépendant du mécanisme de détection
2	Apps → OLTP `DataSubjectRequest`	écr. sync. directe	Le client exerce un droit ou donne/retire son consentement via une application
	Apps → OLTP `ConsentRecord`	"	"
5	Topic `cdc` → staging OLAP	extract. async. cont.	cf. §D1.3.5.
6	`dbt` + staging → OLAP	transf. plan.	cf. §D1.3.5.
7	OLAP → analytiques	req. analytiques	Découplé du chemin transactionnel, pas d'impact sur latence de paiement, consommateur analyste sécurité & conformité
6+7	OLTP → reporting conformité	extract. plan. indé.	Alimente les rapports RGPD/PCI-DSS sans exposer l'OLTP directement aux outils de reporting ; job d'extraction dédié non intégré au pipeline partagé (robustesse aux pannes du sytème)

> *abréviations :*
>
> - lect. = lecture
> - écr. = écriture
> - cont. = continue
> - sync. = synchrone
> - async. = asynchrone
> - pub. = publication
> - ingest. = ingestion
> - détect. = détection
> - transf. = transformation
> - mess. = message
> - req. = requêtes
> - extract. = extraction
> - plan. = planifié
> - indé. = indépendante

D1.x. Technologies (D5)

#	Rôle	Technologies	Remarques	
	OLTP	*PostgreSQL*		
	OLAP	*Snowflake*		
	NoSQL	*MongoDB*	orienté documents	
	bus d'évènement	*Kafka*	topic streams	
	CDC (OLTP)	Write-Ahead-Log (WAL) *PostgreSQL*	CDC = Change Data Capture	
	CS (NoSQL)	CS *MongoDB*	CS = Change Streams	
	Orchestrateur	*Airflow*		
3	OLTP CDC > topics `cdc`	connecteur source *Kafka Connect/Debezium*	ingestion asynchrone continue	
4	topics `app` > NoSQL	connecteur sink *Kafka Connect/MongoDB*	ingestion asynchrone continue	
5	CS NoSQL > staging OLAP	connecteur *Change Streams*	compilation asynchrone continue	
5	topics `cdc` > staging OLAP	connecteur sink *Kafka Connect/Snowflake*	extraction asynchrone continue	
5	topics `fraud` > staging OLAP	connecteur sink *Kafka Connect/Snowflake*	extraction asynchrone continue	
4	actualisation des features : Topics `cdc` > NoSQL `features`	job *Flink*	actualisation des features, asynchrone continue	
4	actualisation du cache marchands : Topics `cdc` > NoSQL `merchants`	job *Flink*	actualisation asynchrone continue	
3🇮	topics `cdc` > topics `security`	relais *Kafka Streams*	relais asynchrone continue	
2🇧	topics `cdc` > OLTP `AuditChangeLog`	connecteur sink *Kafka Connect* + *SMT (Simple Message Transformation)*	asynchrone continue	
2🇧	topics `fraud` > OLTP `FraudScore`	connecteur sink *Kafka Connect*	asynchrone continue	
2🇧	topics `audit` > OLTP `DataAccessLog`	connecteur sink *Kafka Connect*	asynchrone continue	
2🇧	topics `audit` > OLTP `SecurityIncident`	job *Flink*	détection des tentatives suspectes, asynchrone continue	
6	topics `security` > canal de notification	connecteur sink *Kafka Connect/webhook*	ingestion asynchrone continue	

D1.x. Remarques

`event_logs` vs. `audit.access` (D4)

`event_logs` est un journal d'erreur technique ou opérationnelle : une panne de service, un timeout, une exception applicative. `audit.access` trace les accès en lecture des données OLTP.

	`event_logs`	`audit.access`
Question	"Qu'est-ce qui a mal fonctionné techniquement?"	"Qui a consulté quelle donnée?"
Déclencheur	Erreur/exception d'un service	Lecture réussie ou refusée
Exemple	"Card authorization timeout" sur `payment-gateway`	Un agent support consulte le profil d'un client
Alimente	Rien % sécurité/conformité	`DataAccessLog` (OLTP), alerting *Flink* (D5 §D5.8.5)

Reporting Sécurité & Conformité OLTP vs. OLAP (D4)

On a deux types de reporting lié à la *sécurité et à la conformité* :

	Reporting réglementaire	**Reporting analytique**
Consommateur	Délégué à la protection des données (DPO), responsable conformité	Analyste risque, équipe GRC (*Governance, Risk, Compliance*)
Produit	Dépôts légaux, notification de violation, réponse à une demande RGPD	Tableaux de bord de tendance, corrélations, revues périodiques
Contrainte	Délai légal opposable (72h, 30/45j), valeur probante	Aucune échéance légale, exploration libre
Fraîcheur	Nécessaire à l'instant du dépôt	Suffisante avec un décalage batch
Valeur	Traçabilité directe à la source, preuve d'audit	Corrélation avec d'autres dimensions (marchand, segment, temps)
Dépendance	Traçable à la source, isolé du pipeline partagé	Dépend du pipeline OLAP (Kafka/Airflow/dbt)
Source	OLTP	OLAP

Le chemin OLTP est volontairement minimal, aussi proche de la source que possible. D'un autre coté, l'outil de reporting RGPD/PCIDSS ne peut pas avoir de connexion directe à la base transactionnelle (cf. §D1.3 "alimente les rapports [...] sans exposer l'OLTP directement aux outils de reporting") . D'où la nécessité d'un job d'extraction dédié.

D1.x. Sujets non couverts

La sélection des technologies et des outils managés sous-jacents (*MongoDB Atlas*, self-hosted, ou service compatible de type *DocumentDB* est une décision d'infrastructure et d'hébergement hors du périmètre de l'architecture de données.

La sélection du bus d'évènements *Kafka* est une exigence technique dans le *business case* [R0], bien qu'elle soit normalement exclue du périmètre de l'architecture de données proprement dite.

La sélection de l'entrepôt analytique *Snowflake* est une décision prise dans [D5] et justifiée dans [D5-A], mais représentée ici pour permettre au diagramme d'architecture de montrer les choix techniques les plus importants sans avoir à dépendre du document technique [D5].

La stratégie de réplication/failover propre à *OLTP* est détaillée séparément (cf. [D2-C]).

Références

Spécifications

- [D0] Stripe Project Introduction

Livrables

- [D2] OLTP Entity-Relation Diagrams
- [D3] OLAP System Schema Design
- [D4] NoSQL Data Model
- [D5] Data Pipeline Architecture
- [D6] Security and Compliance Plan
- [D7] Machine Learning Integration Strategy

Annexes

- [D2-C] OLTP Supporting Notes
- [D5-A] Data Pipeline Supporting Notes

Annexe : Diagramme d'architecture globale complet

