STRIPE PROJECT

2. OLAP Data System

D3. OLAP System Schema Design

> *Nicolas Pichon --- AIA RNCP 38777 / BC02 / D3 : OLAP System Schema Design / v22 --- 2026/11/05.*

- D3.1. Contexte
- D3.2. Schémas en étoile
- D3.3. Les étoiles des processus métiers
  - D3.3.1. Revenus (P1/FactTransaction)
  - D3.3.2. Fraudes (P2/FactFraudEvent)
  - D3.3.3. Abonnements (P3/FactSubscriptionSnapshot)
  - D3.3.4. Lectures et écritures (P4/FactAuditEvent)
  - D3.3.5. Demandes de droits (P5/FactDataSubjectRequest)
  - D3.3.6. Incidents de sécurité (P6/FactSecurityIncident)
- D3.4. Stratégie d'agrégation
- D3.5. Techniques d'optimisation des requêtes
  - D3.5.1. Clés de substitution entière
  - D3.5.2. `DimDate` précalculées
  - D3.5.3. Partitionnement par `date_key`
  - D3.5.4. Stockage orienté colonnes
  - D3.5.5. Diffusion des dimensions
  - D3.5.6. Taux de change de référence fixe
  - D3.5.7. Sécurité RLS
  - D3.5.8. Index ciblés
- D3.6. Règles de transformation (ETL)
- Références

D3.1. Contexte

Ce document présente le schéma de l'entrepôt analytique :

- organisation du schéma en étoiles,
- stratégie d'agrégation,
- techniques d'optimisation des requêtes.

> Convention de notation des cardinalités dans les diagrammes présentés (notation *crow's foot*) :
> `||` = un et un seul, `o{` = zéro à plusieurs.

L'analyse préliminaire des processus métiers est donnée en annexe [D3-A]. Six processus sont identifiés en se basant sur les catégories des données analytiques présentées dans le cahier des charges [D0] :

#	Processus métier	Source de données analytiques
P1	Traitement d'un paiement	*Revenue Metrics*, *Product Performance*, *Customer Segmentation*
P2	Évaluation du risque de fraude	*Fraud Analysis Data*
P3	Cycle de vie d'un abonnement	*Revenue Metrics*
P4	Accès et modification de données	*Compliance and Audit Logs*
P5	Traitement d'une demande de droit	*Compliance and Audit Logs*
P6	Traitement d'un incident de sécurité	*Compliance and Audit Logs*

Événements déclencheurs

P1	Traitement d'un paiement	Création d'une transaction
P2	Évaluation du risque de fraude	Calcul d'un score de fraude
P3	Cycle de vie d'un abonnement	Arrivée à échéance d'un abonnement
P4	Accès et modification de données	Journalisation d'une consultation ou d'une modification
P5	Traitement d'une demande de droit	Demande d'application d'un droit RGPD/CCPA
P6	Traitement d'un incident de sécurité	Détection d'un incident de sécurité

D3.2. Schémas en étoile

Dans le schéma en étoile (*star schema*), chaque *dimension* est directement reliée à la *table de faits*, sans hiérarchie de sous-dimensions normalisées.

Justification

L'architecture en flocons (*snowflake schema*) réduit la redondance au prix de jointures supplémentaires. En lecture analytique, c'est l'inverse de l'objectif recherché. La *dénormalisation* assumée dans les dimensions coûte en stockage mais gagne en temps de requête.

Dimensions indépendantes

Aucune dimension ne référence une autre dimension : seules les tables de faits portent des clés étrangères vers les dimensions.

`DimMerchant` étant une *SCD2* (*), une clé étrangère (`key`) de type `DimCustomer` → `DimMerchant` désignerait une version spécifique du marchand et obligerait à versionner tous ses clients, produits et plans tarifaires à chaque changement du marchand. `DimCustomer` , `DimProduct` et `DimPricingPlan` portent donc `merchant_id` (la clé métier de l'OLTP) seule. La version de marchand d'une ligne de fait (*fact*) reste identifiée par `merchant_key` .

De même, `DimReferenceExchangeRate` identifie la devise source par `from_currency_code` , sans clé étrangère vers `DimCurrency` [D3-A, §2.A.4].

> (*) *SCD2* = *Slowly Changing Dimension of Type 2* où *Type 2* signifie que chaque modification est versionnée.

D3.3. Les étoiles des processus métiers

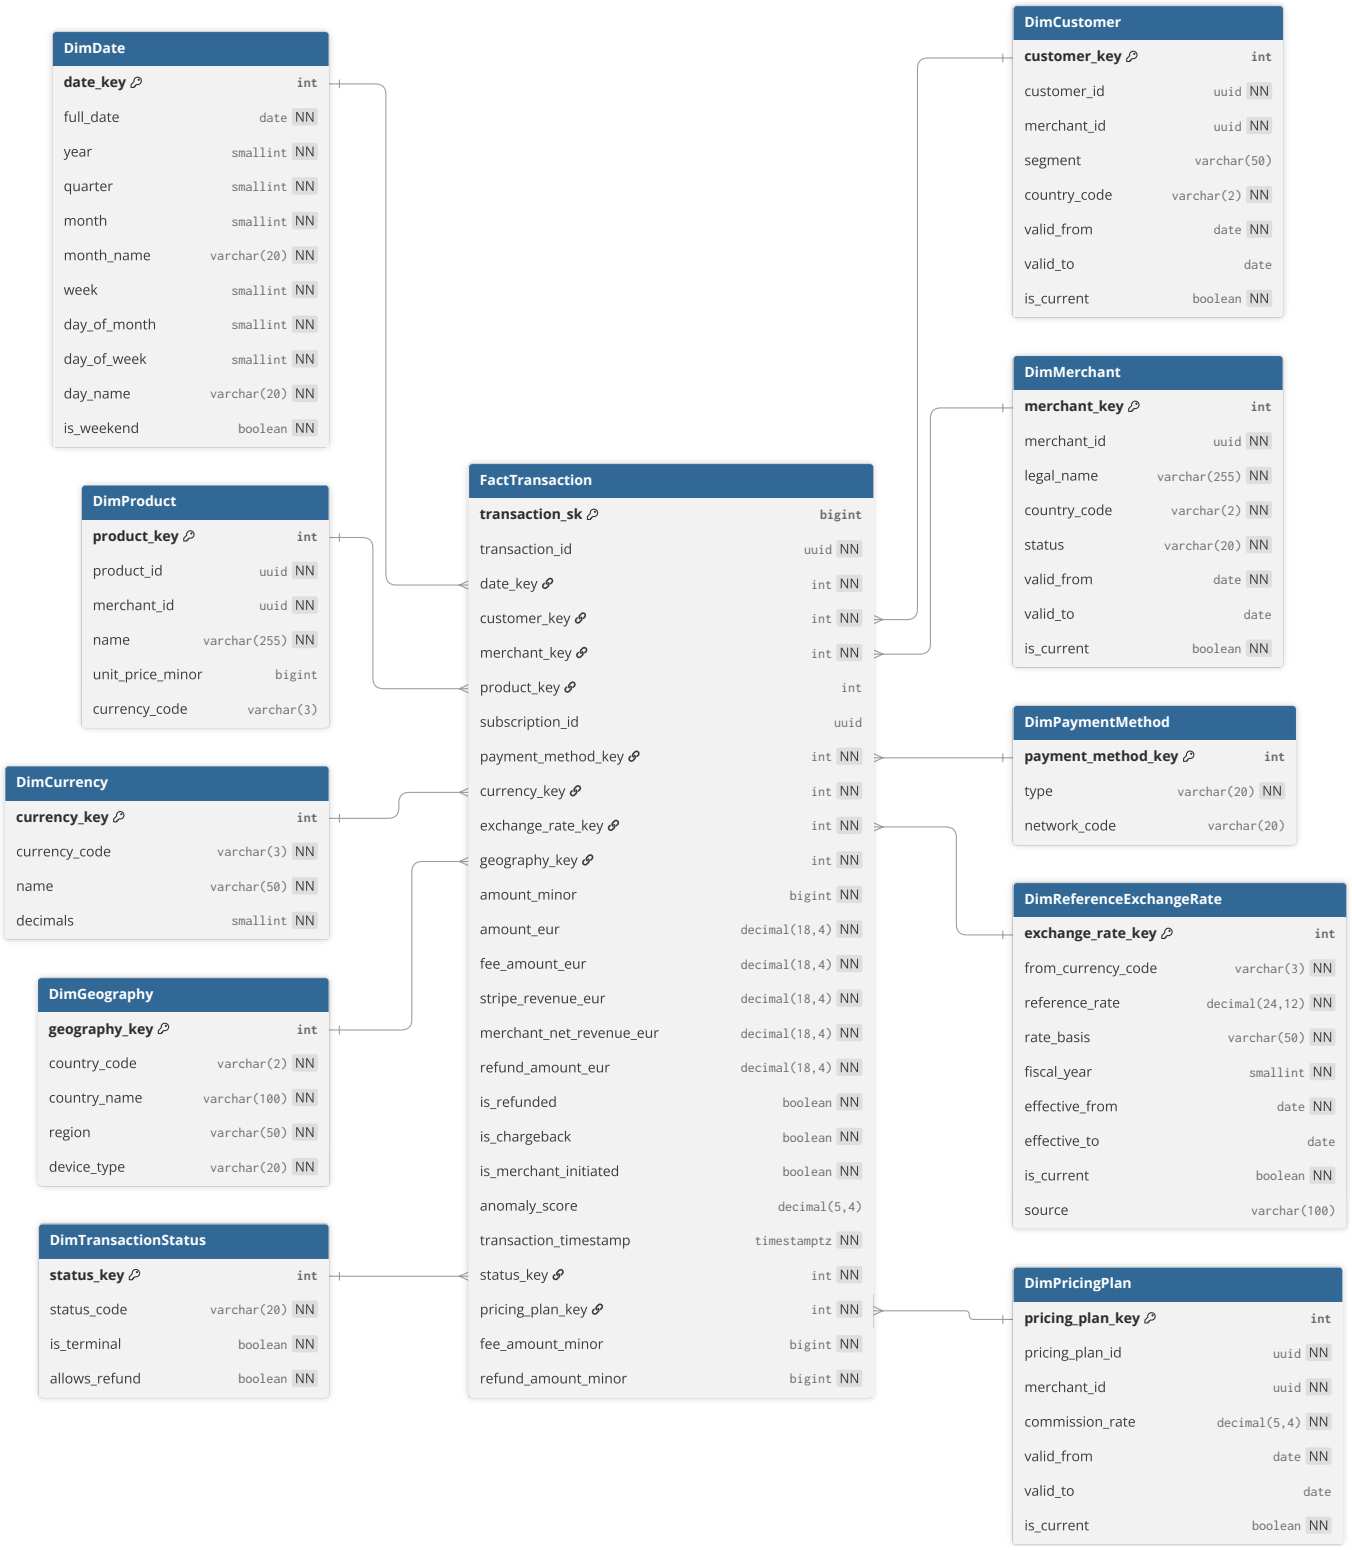
Les diagrammes ci-dessous présentent les schémas en étoile de chaque processus métier.

Chaque étoile a son propre diagramme :

- *Transactions* (P1),
- *Fraudes* (P2),
- *Abonnements* (P3),
- *Lectures et écritures des données* (P4),
- *Demandes de droit* (P5),
- *Incidents de Sécurité* (P6).

> Rappel : chaque processus métier a son propre *grain*. Les étoiles ne partagent aucune ligne, seulement des dimensions conformées (`DimDate` , `DimMerchant` , `DimCustomer` , `DimGeography` ...), voir la matrice de bus [D3-A, §2.A.6].

D3.3.1. Revenus (P1/FactTransaction)



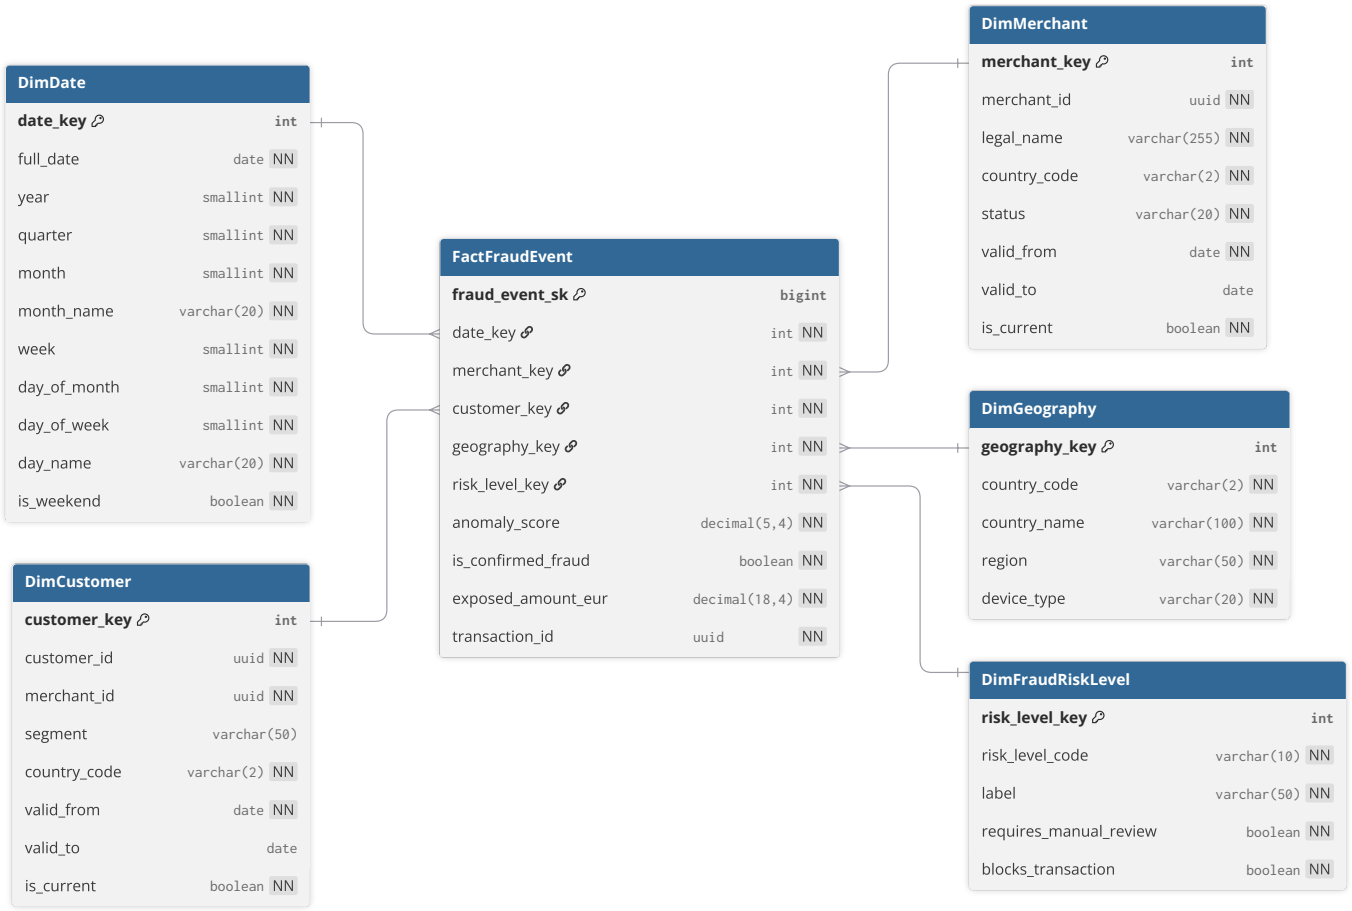
Grain : `FactTransaction` (une transaction).

Les propriétés `merchant_net_revenue_eur` et `stripe_revenue_eur` cohabitent sur la même ligne. Les deux audiences du reporting (marchands & Stripe) lisent la même table, seule la colonne agrégée change (voir note dans le modèle physique [D3-B]).

Montants : entiers en unités mineures (`amount_minor` , `fee_amount_minor` , `refund_amount_minor`) et valeurs en EUR (`decimal(18,4)`) converties au taux de référence (règles en D3.5.6). La commission `fee_amount_minor` est reprise de l'OLTP (`Transaction.fee_amount`) ; elle n'est **jamais recalculée** côté OLAP.

Géographie : `geography_key` (non nulle) désigne le pays où la transaction a été initiée et le type d'appareil. Le pays est résolu à l'ETL à partir de `Transaction.ip_geolocation` (adresse IP, GeoIP en version figée) ; l'adresse IP n'est jamais copiée dans l'OLAP (RGPD). Une IP absente ou non résolue donne le membre par défaut « unknown » (`country_code = 'ZZ'`).

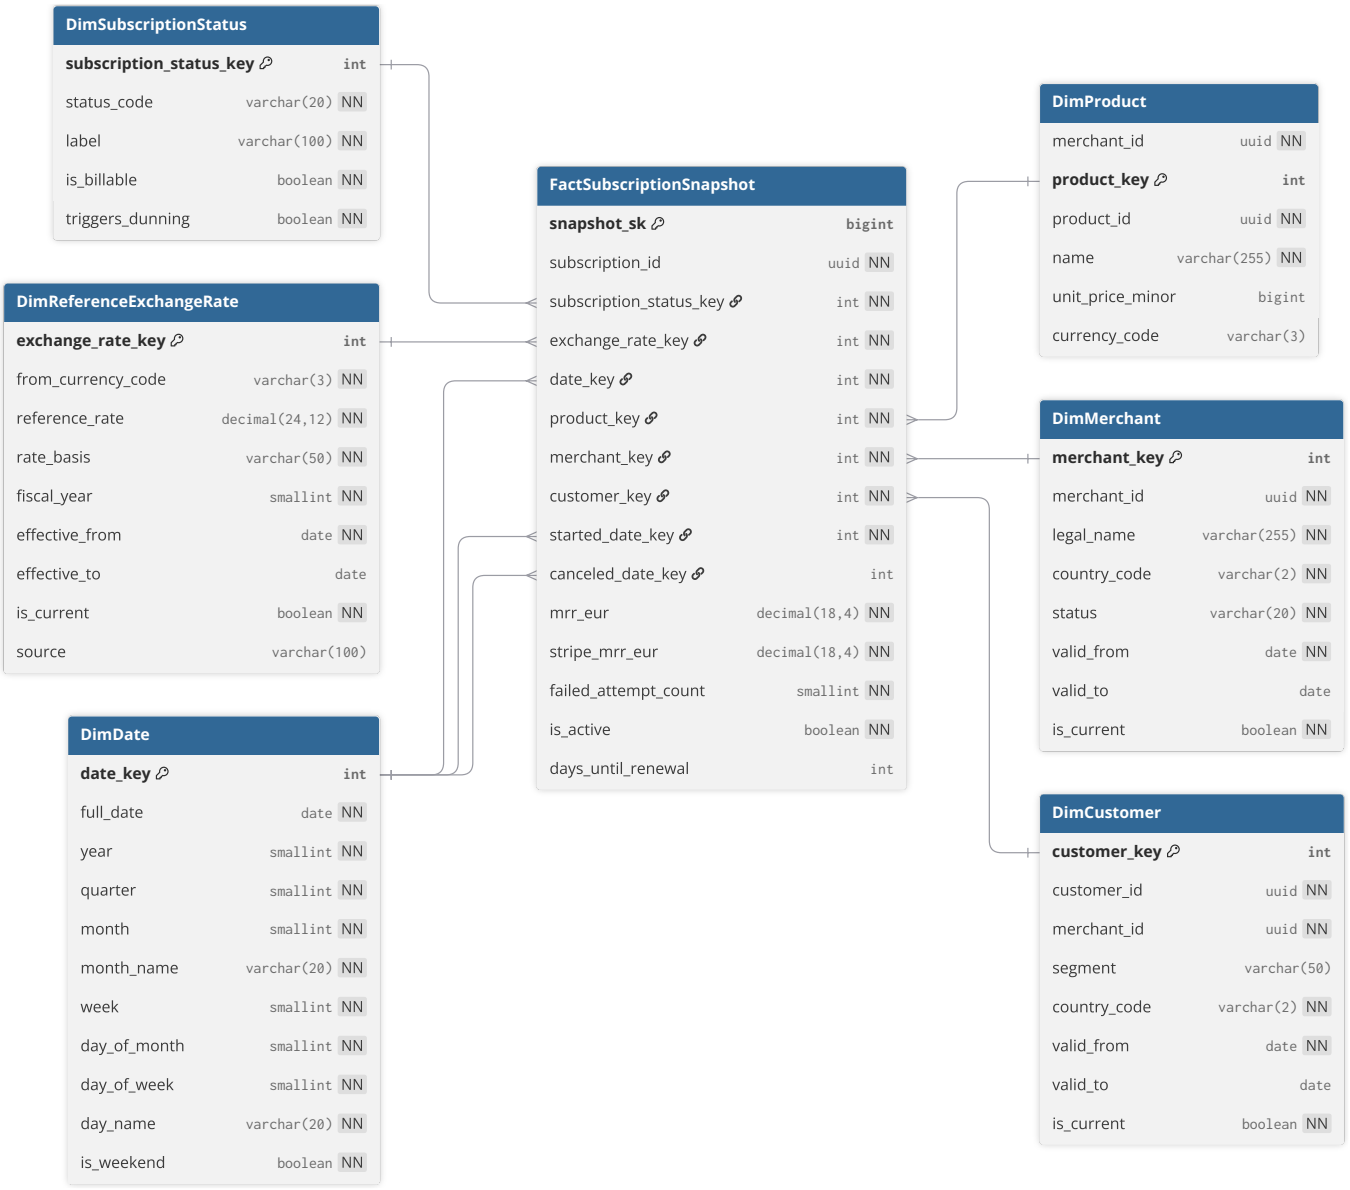
D3.3.2. Fraudes (P2/FactFraudEvent)



Grain : un événement d'évaluation du risque de fraude (fait transactionnel). `is_confirmed_fraud` est la seule colonne mise à jour après l'insertion, quand la décision de fraude est confirmée [D3-A] (2.A.3) et [D3-C] (ETL-02).

`date_key` est la date UTC de l'évaluation (`FraudScore.evaluated_at`). `geography_key` est non nulle et résolue comme pour `FactTransaction` (D3.3.1) ; `exposed_amount_eur` est converti au taux de référence (D3.5.6).

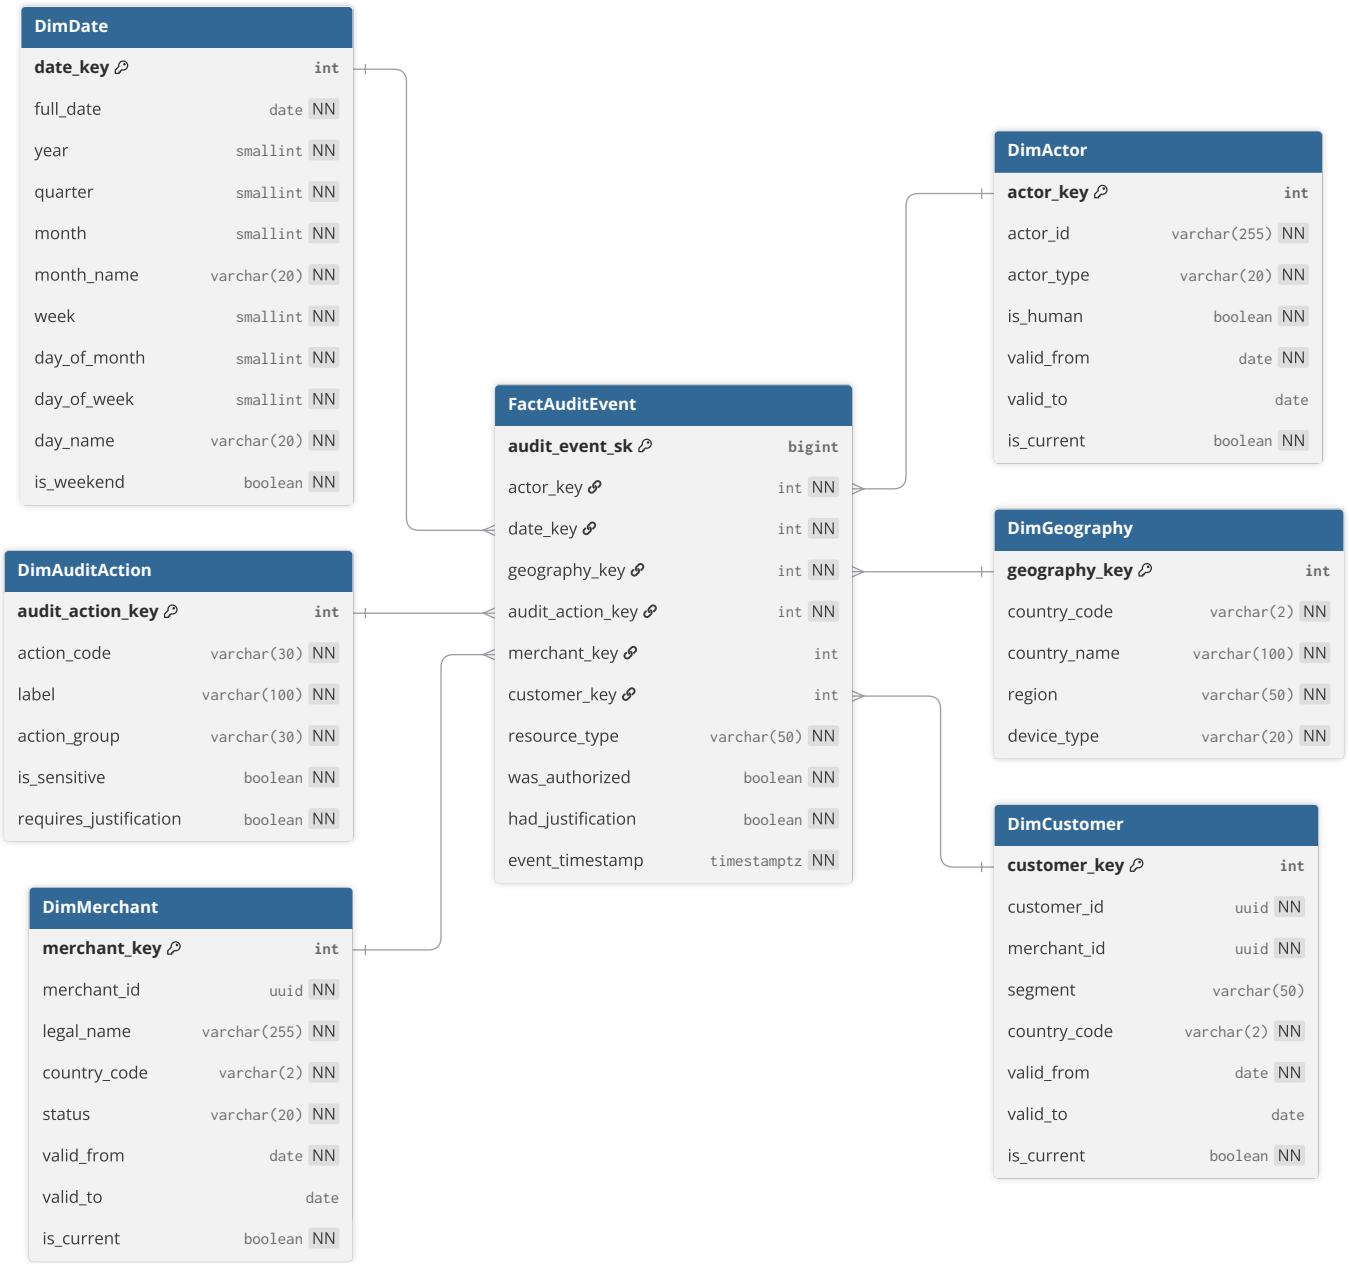
D3.3.3. Abonnements (P3/FactSubscriptionSnapshot)



Grain : `FactSubscriptionSnapshot` (un instantané d'abonnement capturé périodiquement).

`mrr_eur` et `stripe_mrr_eur` décrivent un état à un instant donné, et non un événement : ils sont semi-additifs (à ne pas sommer sur plusieurs dates pour un même abonnement). Ils sont convertis au taux de référence fixe (D3.5.6) : `exchange_rate_key` désigne le taux retenu, donc aussi la devise de l'abonnement (`from_currency_code`). `date_key` est la date UTC de l'instantané. `started_date_key` (début de l'abonnement) et `canceled_date_key` (demande de résiliation, vide s'il n'y en a pas) sont deux autres rôles de `DimDate` ; elles alimentent `new_subscriptions` et `churned_count` de `AggSubscriptionDailyMerchant` . Une résiliation demandée n'arrête pas l'abonnement avant la fin de la période déjà facturée : `churned_count` compte des demandes de résiliation, pas des abonnements terminés [D3-C] (2.C.2 et 2.C.3.6).

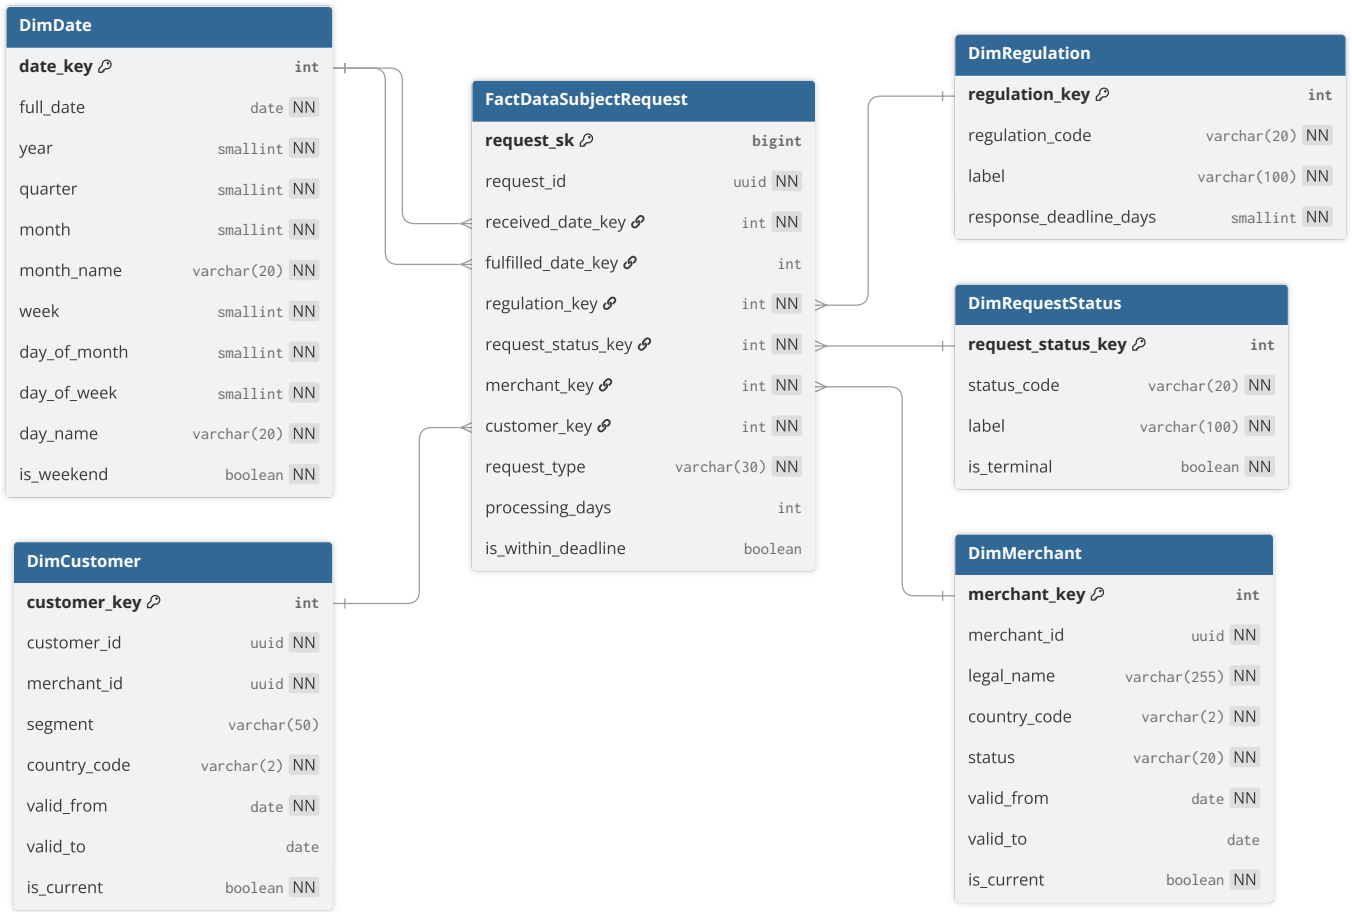
D3.3.4. Lectures et écritures (P4/FactAuditEvent)



Grain : un événement d'audit, accès (`DataAccessLog`) **ou** modification (`ChangeAuditLog`).

`geography_key` est non nulle. Pour les accès, le pays est résolu depuis `DataAccessLog.source_ip` ; pour les modifications (alimentées par CDC, sans IP dans l'OLTP), la ligne reçoit le membre « unknown ». `device_type` vaut toujours `unknown` pour ce fait : une analyse par pays ne couvre donc que les accès [D3-A] (2.A.4). `event_timestamp` est un `timestamptz` UTC.

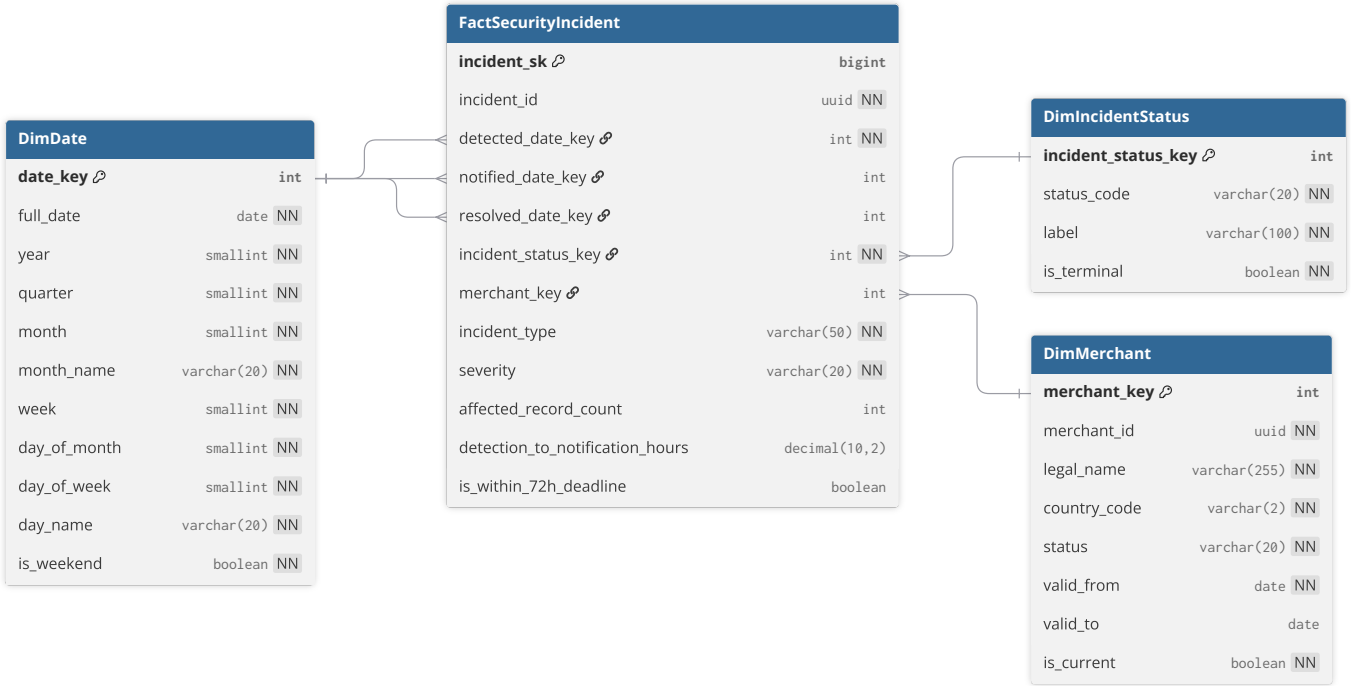
D3.3.5. Demandes de droits (P5/FactDataSubjectRequest)



Grain : une demande de droit, mise à jour au fur et à mesure de son traitement.

`FactDataSubjectRequest` référence `DimDate` deux fois (`received_date_key` à la réception, `fulfilled_date_key` au traitement, renseignée plus tard). C'est la signature d'un instantané cumulatif *Kimball* : plusieurs jalons temporels sur une même ligne, mise à jour au fur et à mesure du processus, au lieu de créer une nouvelle ligne par événement.

D3.3.6. Incidents de sécurité (P6/FactSecurityIncident)



Grain : un incident de sécurité, mis à jour au fur et à mesure de son traitement.

`FactSecurityIncident` référence `DimDate` trois fois (`detected_date_key` , `notified_date_key` , `resolved_date_key` : détection, notification, résolution) : même logique d'instantané cumulatif que pour D3.3.5. Cette étoile ne porte ni `DimCustomer` ni `DimGeography` .

D3.4. Stratégie d'agrégation

Principe constant : *le fait atomique reste au grain le plus fin, les agrégats sont des tables séparées, calculées.*

Dénormalisation différenciée entre fait atomique et agrégat : le fait atomique référence toujours une dimension par clé (`regulation_key` , par exemple) pour permettre n'importe quel angle d'analyse ; l'agrégat précalculé garde parfois l'attribut en clair (par exemple, `regulation` dans `AggDataSubjectRequestMonthly`) pour pouvoir être interrogeable sans jointure (noter qu'un agrégat n'a pas vocation à être recombiné avec d'autres dimensions, il doit juste répondre vite à une question déjà posée).

Les tableaux suivants exposent les tables d'agrégation présentes dans le modèle physique [D3-B].

Table d'agrégat	Grain	Sources
`AggRevenueDailyMerchant`	Jour × marchand	`FactTransaction`
`AggRevenueMonthlyMerchantCountry`	Mois × marchand × pays	`FactTransaction`
`AggFraudDailyMerchant`	Jour × marchand	`FactFraudEvent`
`AggSubscriptionDailyMerchant`	Jour × marchand × produit	`FactSubscriptionSnapshot`
`AggComplianceDailyMerchant`	Jour × marchand	`FactAuditEvent`
`AggDataSubjectRequestMonthly`	Mois × marchand × réglementation × type	`FactDataSubjectRequest`
`AggSecurityIncidentMonthly`	Mois × marchand × sévérité	`FactSecurityIncident`

Usages

`AggRevenueDailyMerchant`	Tableau de bord marchand (quasi temps réel)
`AggRevenueMonthlyMerchantCountry`	Reporting géographique
`AggFraudDailyMerchant`	Alerting fraude
`AggSubscriptionDailyMerchant`	Tableau de bord des abonnements
`AggComplianceDailyMerchant`	Reporting de conformité automatisé
`AggDataSubjectRequestMonthly`	Rapport de suivi RGPD/CCPA
`AggSecurityIncidentMonthly`	Rapport de sécurité

D3.5. Techniques d'optimisation des requêtes

D3.5.1. Clés de substitution entière

Déclarer les clés de substitution comme des entiers plutôt que des identifiants UUID.
Le format entier est nécessaire pour mettre en place un versionnement *SCD2* (un même `merchant_id` dans la base OLTP correspondra à plusieurs `merchant_key` dans la base OLAP, au fur et à mesure des modification de l'entité marchande).

D3.5.2. `DimDate` précalculées

Un pré-calcul des informations d'horodatage dans `DimDate` évite les fonctions de date dans les clauses `WHERE` (`EXTRACT` , `DATE_TRUNC` ...). Les fonctions de date empêchent l'*élagage de partitions* dans la plupart des moteurs orientés colonnes. `DimDate` permet aussi de faire des comparaisons période sur période par simple jointure sur `date_key` .

Fuseau horaire : tout est en UTC [D3-C] (2.C.2). `date_key` (et chaque `*_date_key`) est la date UTC de l'événement ; les horodatages sont des `timestamptz` (jamais un `timestamp` sans fuseau) ; « aujourd'hui » s'écrit `(now() AT TIME ZONE 'UTC')::date` et non `CURRENT_DATE` , qui dépend du fuseau de la session. Il n'y a ni `DimTime` ni fuseau local par marchand : l'extension (`Merchant.timezone` , `local_date_key`) n'est pas retenue en l'absence de besoin exprimé.

D3.5.3. Partitionnement par `date_key`

Le partitionnement par `date_key` (date UTC) est systématique sur les tables de faits à fort volume (`FactTransaction` , `FactAuditEvent`). Il est mensuel ou quotidien selon le volume réel.
L'*élagage de partitions* élimine la majorité des lignes avant même le scan.

D3.5.4. Stockage orienté colonnes

Systèmes courants : *Redshift*, *BigQuery*, *Snowflake* ou *ClickHouse* ; cohérent avec des requêtes qui agrègent peu de colonnes sur beaucoup de lignes (l'inverse du pattern *OLTP*).

D3.5.5. Diffusion des dimensions

Diffusion des dimensions (*broadcast join*). Les dimensions restent petites en volume (quelques milliers à millions de lignes, jamais à l'échelle des faits) - elles peuvent être répliquées sur chaque nœud de calcul plutôt que redistribuées, évitant un *shuffle* coûteux lors de la jointure avec une table de faits partitionnée.

D3.5.6. Taux de change de référence fixe

Taux de change fixe (`DimReferenceExchangeRate`). Au-delà de la comparabilité déjà justifiée [D3-C] (2.C.1), c'est aussi une optimisation : convertir au vol au taux du jour demanderait une jointure sur une dimension à cardinalité temporelle fine ; le taux figé par exercice réduit drastiquement le nombre de versions à joindre.

Règle de conversion et types [D3-C] (2.C.1) :

- montants locaux : `bigint` en unités mineures (`*_minor`), l'échelle étant portée par `DimCurrency.decimals` ;
- `amount_eur = amount_minor / 10^decimals × reference_rate` , où `reference_rate` (`decimal(24,12)`) est exprimé en EUR pour 1 unité majeure de la devise source ;
- montants en EUR : `decimal(18,4)` , calculés une seule fois à l'ETL en décimal exact, arrondis à la 4e décimale (demi-supérieur) ; l'arrondi à 2 décimales est réservé à l'affichage ;
- une seule conversion par composante (montant, commission, remboursement) ; les mesures dérivées sont calculées sur les valeurs déjà converties ;
- le taux retenu est celui de (devise source, exercice) pour la date de création UTC de la transaction (pour un instantané d'abonnement : la date de l'instantané) ;
- la commission est reprise de l'OLTP et n'est jamais recalculée.

D3.5.7. Sécurité RLS

Sécurité au niveau des lignes (RLS), pas de filtrage applicatif. Un marchand consultant son reporting ne doit voir que ses propres lignes ; imposé par une politique RLS au niveau du moteur, jamais laissé à la charge de la requête applicative, pour qu'aucun bug côté client ne puisse exposer les données d'un autre marchand.

La politique repose sur l'identifiant stable `merchant_id` , et non sur `merchant_key` : `DimMerchant` étant en *SCD2*, un marchand possède une `merchant_key` par version, et une politique `merchant_key = X` lui masquerait son historique. Elle s'applique ainsi :

- **faits et agrégats** (qui portent `merchant_key`) : `merchant_key` doit appartenir à l'ensemble des clés du marchand de la session (`merchant_key IN (SELECT merchant_key FROM DimMerchant WHERE merchant_id = <marchand de la session>)`) ;
- **dimensions propres à un marchand** (`DimMerchant` , `DimCustomer` , `DimProduct` , `DimPricingPlan`) : `merchant_id` égal à celui de la session. Les autres dimensions sont des référentiels partagés ;
- **lignes sans marchand** (`merchant_key` nul dans `FactAuditEvent` et `FactSecurityIncident`) : n'appartenant à aucun marchand, elles ne sont pas visibles par cette politique ; leur lecture par les rôles internes reste à définir [D3-C] (2.C.3.8, O-08).

D3.5.8. Index ciblés

Index ciblés sur les clés de jointure et les colonnes de filtrage fréquent - `date_key` et `(merchant_key, date_key)` systématiques sur les faits, complétés par les clés métier (`transaction_id` , `(subscription_id, date_key)` , `request_id` , `incident_id` ...) pour le dédoublonnage à l'ETL et le rapprochement avec l'OLTP, et par `merchant_id` sur `DimMerchant` , `DimCustomer` , `DimProduct` et `DimPricingPlan` (filtre RLS).

D3.6. Règles de transformation (ETL)

Les valeurs que l'OLTP ne fournit pas telles quelles (segment client, regroupement des actions d'audit, remboursement et litige, fraude confirmée, MRR et compteurs d'abonnements, valeurs des événements d'écriture) sont définies par des règles numérotées `ETL-nn` , réunies dans [D3-C] (2.C.3) et citées dans les notes du modèle physique [D3-B]. Trois principes les gouvernent : la version de dimension SCD2 est celle en vigueur le jour UTC du fait ; seules quelques colonnes d'indicateurs sont mises à jour après l'insertion d'un fait (remboursement, litige, fraude confirmée) ; un rechargement redonne les mêmes lignes. Les seuils de segmentation et certains mappings sont des hypothèses de conception, signalées comme telles. Les politiques et règles non encore définies sont exposées en [D3-C] (2.C.3.8).

Références

Spécifications

- [D0] Stripe Project Introduction

Annexes

- [D3-A] OLAP Kimball Analysis
- [D3-B] OLAP Physical Data Model
- [D3-C] OLAP Conventions and Transformation Rules