STRIPE PROJECT

> *Nicolas Pichon - AIA RNCP 38777 / BC02 / Exercise Guide / v01 - 2026/10/13.*

- 1. Introduction
- 2. Enjeux Stratégiques
- 3. Exigences d'affaire
- 4. Exigences techniques
- 5. Sources de données
- 6. Livrables
- 7. Traçabilité des exigences
- Références

1. Introduction

1.1. Contexte

Stripe est une entreprise de technologie financière de premier plan, fondée en 2010, et basée à San Francisco, en Californie. Elle propose une suite complète de produits pour gérer les paiements et les opérations financières des entreprises de toutes tailles. Elle accompagne des millions de marchands dans le monde entier et traite des milliards de transactions chaque année. À mesure que la société se développe, elle fait face à une complexité croissante dans la gestion de ses données réparties sur différentes plateformes, incluant les systèmes transactionnels (OLTP), les systèmes analytiques (OLAP) et les bases de données non relationnelles (NoSQL).

1.2. Objectifs de l'exercice

Stripe souhaite construire une infrastructure de données de pointe qui intègre de manière fluide ces différents types de systèmes afin de soutenir à la fois l'excellence opérationnelle et l'analyse avancée. L'objectif de cet exercice est de créer une architecture de données unifiée et évolutive, capable de gérer de gros volumes de données transactionnelles, de supporter des requêtes analytiques complexes, et de gérer des données non structurées pour des cas d'usage avancés tels que la détection de fraude, l'analyse du comportement client et les recommandations en temps réel.

2. Enjeux stratégiques

2.1. Synopsis

Les enjeux stratégiques de l'exercice sont les suivants :

#	Enjeu stratégique (fr)	Business Objective (en)
C1	Charges transactionnelles complexes	Complex Transactional Workloads
C2	Besoins avancés en matière d'analytique	Advanced Analytics Requirements
C3	Gestion des données non structurées et semi-structurées	Handling Unstructured and Semi-Structured Data
C4	Intégration des données entre systèmes	Data Integration Across Systems
C5	Sécurité e conformité	Security & Compliance

2.2. Descriptions détaillées

C1. Complex Transactional Workloads

Les systèmes *OLTP* de *Stripe* traitent des millions de transactions chaque jour, avec des exigences élevées en matière de disponibilité, de cohérence et de rapidité. Ces transactions incluent les paiements, les remboursements (refunds), les rétro-facturations (chargebacks) et la gestion des abonnements. L'entreprise doit s'assurer que ces systèmes sont hautement disponibles, évolutifs et capables de supporter de nouvelles fonctionnalités comme la détection de fraude en temps réel.

C2. Advanced Analytics Requirements

Stripe doit fournir une analytique robuste à ses clients et aux parties prenantes internes. Cela inclut l'analyse des revenus, la segmentation client, le reporting de conformité et le suivi de la performance des différents produits. L'entreprise a besoin d'un système *OLAP* capable de traiter des requêtes complexes efficacement, de supporter l'analyse ad hoc, et de fournir des insights quasi temps réel.

C3. Handling Unstructured and Semi-Structured Data

Stripe collecte de grandes quantités de données non structurées et semi-structurées, telles que les journaux (logs), les retours clients et les données d'interaction issues de son site web et de ses applications mobiles. Ces données sont essentielles pour construire des modèles de machine learning dédiés à la détection de fraude, à la personnalisation client et à l'analyse prédictive. L'entreprise a besoin d'une base de données *NoSQL* capable de stocker et traiter efficacement ces données, de les intégrer aux données relationnelles, et d'offrir des capacités de requêtage flexibles.

C4. Data Integration Across Systems

Intégrer les données entre les systèmes *OLTP*, *OLAP* et *NoSQL* constitue un défi majeur. *Stripe* a besoin d'une architecture de données unifiée permettant une circulation fluide des données entre ces systèmes, garantissant que les données restent cohérentes, à jour et accessibles pour les différents cas d'usage.

C5. Security & Compliance

Étant donné la nature sensible des données financières, *Stripe* doit s'assurer que son architecture de données respecte les réglementations telles que le RGPD, la norme PCI-DSS et le CCPA. L'entreprise doit également mettre en œuvre des mesures de sécurité robustes pour protéger les données au repos et en transit, gérer les contrôles d'accès, et surveiller l'utilisation des données.

3. Exigences d'affaire

3.1. Synopsis

Les enjeux stratégiques de l'exercice sont les suivants :

#	Exigence d'affaire (fr)	Business Requirement (en)
BR1	Intégrité transactionnelle	Transactional Integrity (OLTP)
BR2	Analytique évolutive et efficace	Scalable and Efficient Analytics (OLAP)
BR3	Gestion flexible des données	Flexible Data Management (NoSQL)
BR4	Intégration et cohérence des données	Data Integration Across Systems
BR5	Sécurité et conformité	Security & Compliance

3.2. Descriptions détaillées

BR1. Transactional Integrity

Les systèmes *OLTP* de *Stripe* doivent gérer de gros volumes de transactions avec une latence minimale. Le système doit respecter les propriétés ACID afin de garantir la cohérence et l'intégrité des données dans des environnements distribués. Il doit également supporter des fonctionnalités telles que les transactions multi-documents, la synchronisation des données en temps réel, et la reprise après sinistre (disaster recovery).

BR2. Scalable and Efficient Analytics

Le système *OLAP* doit supporter des requêtes complexes sur de grands ensembles de données. Il doit être capable d'agréger les données selon plusieurs dimensions, de supporter l'analyse de séries temporelles, et de gérer des jointures et sous-requêtes à grande échelle. Le système doit fournir des réponses à faible latence pour les requêtes métier critiques et supporter à la fois l'analyse historique et l'analyse quasi temps réel.

BR3. Flexible Data Management

Stripe a besoin d'un système *NoSQL* capable de gérer des types de données variés, incluant le JSON, le XML et les données binaires. Le système doit supporter une conception de schéma flexible, permettre un requêtage efficace des données imbriquées et non structurées, et s'intégrer avec les autres systèmes de données afin d'offrir une vue globale et cohérente des données.

BR4. Data Integration and Consistency

L'architecture de données doit garantir une circulation cohérente des données entre les systèmes *OLTP*, *OLAP* et *NoSQL*. *Stripe* doit mettre en œuvre des pipelines de données capables de gérer le traitement par lots (batch), les flux de données en continu (streaming), et la synchronisation en temps réel. L'architecture doit supporter les processus *ETL*/*ELT* et permettre la transformation et l'enrichissement des données.

BR5. Security and Compliance

L'architecture de données doit inclure des mesures de sécurité robustes, telles que le chiffrement, les contrôles d'accès et la journalisation d'audit. *Stripe* doit s'assurer que son stockage et son traitement des données respectent les exigences réglementaires des différentes juridictions. Le système doit supporter un reporting de conformité automatisé et une surveillance en temps réel des failles de sécurité.

4. Exigences techniques

4.1. Synopsis

Les enjeux stratégiques de l'exercice sont les suivants :

#	Exigence Technique (fr)	Technical Requirement (en)
TR1	Conception des modèles de données	Data Model Design (OLTP, OLAP, NoSQL)
TR2	Architecture du pipeline de données	Data Pipeline Architecture
TR3	Optimisation de l'évolutivité et des performances	Scalability and Performance Optimization
TR4	Cohérence et synchronisation des données	Data Consistency and Synchronization
TR5	Sécurité et conformité	Security & Compliance
TR6	Analytique avancée et machine learning	Advanced Analytics and Machine Learning

4.2. Descriptions détaillées

TR1. Data Model Design

Concevoir des modèles de données pour chaque type de système :

- **OLTP** : privilégier des schémas normalisés, l'intégrité transactionnelle et l'optimisation des performances.
- **OLAP** : concevoir des schémas en étoile ou en flocon pour un requêtage et une agrégation efficaces. Inclure des tables pré-agrégées pour les requêtes courantes.
- **NoSQL** : concevoir des schémas flexibles supportant les données non structurées et permettant un requêtage et une récupération de données efficaces.

TR2. Data Pipeline Architecture

Développer un *pipeline* de données intégrant les systèmes *OLTP*, *OLAP* et *NoSQL*. Le pipeline doit supporter le traitement par lots et en temps réel, ainsi que la transformation et l'enrichissement des données. Envisager l'utilisation d'outils tels qu'*Apache Kafka* pour le streaming de données en temps réel et *Apache Airflow* pour l'orchestration des processus ETL.

TR3. Scalability and Performance Optimization

S'assurer que l'architecture de données peut monter en charge horizontalement pour gérer des volumes de données croissants. Mettre en œuvre des stratégies d'indexation, de partitionnement et de mise en cache afin d'optimiser les performances sur l'ensemble des systèmes. Envisager l'utilisation de bases de données distribuées et du sharding pour garantir une haute disponibilité.

TR4. Data Consistency and Synchronization

Mettre en œuvre des mécanismes garantissant la cohérence des données entre les systèmes *OLTP*, *OLAP* et *NoSQL*. Envisager des modèles de cohérence à terme (*eventual consistency*) lorsque cela est pertinent, et mettre en œuvre des stratégies de résolution de conflits pour les données distribuées. Utiliser des techniques de *CDC* (*Change Data Capture*) pour maintenir les données synchronisées en temps réel.

TR5. Security and Compliance

Concevoir un cadre de sécurité incluant le chiffrement des données, le contrôle d'accès basé sur les rôles (RBAC) et la journalisation d'audit. S'assurer que l'architecture respecte les réglementations en vigueur (ex. RGPD, PCI-DSS). Mettre en œuvre des contrôles de conformité automatisés et des fonctionnalités de reporting.

TR6. Advanced Analytics and Machine Learning

Intégrer des modèles de *machine learning* au sein du système *NoSQL* pour la détection de fraude en temps réel et la personnalisation client. S'assurer que le pipeline de données supporte l'extraction de caractéristiques (*feature extraction*) et le déploiement de modèles. Prévoir des mécanismes de suivi de la performance des modèles et de mise à jour.

5. Sources de données

5.1. Synopsis

#	Source de données (fr)	Data Source (en)
DS1	Données transactionnelles	Transactional Data (OLTP)
DS2	Données analytiques	Analytical Data (OLAP)
DS3	Données non structurées et semi-structurées	Unstructured and Semi-Structured Data (NoSQL)
DS4	Données de référence	Reference Data

5.2. Descriptions détaillées

DS1. Transactional Data

Capturent l'ensemble des transactions financières traitées par *Stripe*. Champs inclus :

- Identifiant de transaction
- Identifiant marchand
- Identifiant client
- Montant de la transaction
- Devise
- Moyen de paiement
- Date et heure de la transaction
- Localisation (géolocalisation par IP)
- Type d'appareil (mobile, ordinateur, etc.)
- Statut (réussie, échouée, remboursée)
- Indicateurs de fraude (ex. scores d'anomalie)

DS2. Analytical Data

Données agrégées et historiques utilisées pour le reporting et l'analyse. Champs inclus :

- Indicateurs de revenus (journaliers, hebdomadaires, mensuels)
- Données de segmentation client
- Indicateurs de performance produit
- Données d'analyse de la fraude
- Journaux de conformité et d'audit

DS3. U/S and S/S Data

Données collectées depuis diverses sources, telles que les journaux, les interactions clients et les données générées par des machines. Champs inclus :

- Données de journaux (journaux d'erreurs, journaux d'accès)
- Données d'interaction utilisateur (données de clics, données de session)
- Caractéristiques (features) de machine learning (données d'entrée des modèles)
- Retours clients (avis, réponses aux enquêtes)

DS4. Reference Data

Données statiques ou évoluant lentement, utilisées à travers l'ensemble des systèmes :

- Codes pays et région
- Taux de change des devises
- Informations sur les marchands
- Catalogues produits

6. Livrables

6.1. Synopsis

#	Livrable (fr)	Deliverable (en)
D1	Diagramme d'architecture de données complet	Comprehensive Data Architecture Diagram
D2	ERD pour le système OLTP	ERD for OLTP System
D3	Conception du schéma pour le système OLAP	Schema Design for OLAP System
D4	Modèle de données NoSQL	NoSQL Data Model
D5	Architecture du pipeline de données	Data Pipeline Architecture
D6	Plan de sécurité et de conformité	Security and Compliance Plan
D7	Stratégie d'intégration du machine learning	Machine Learning Integration Strategy
D8	Requêtes SQL et NoSQL	SQL and NoSQL Queries

6.2. Descriptions détaillées

D1. Data Architecture Diagram

Diagramme détaillé montrant l'intégration des systèmes de données (*OLTP*, *OLAP*, *NoSQL*), incluant les flux de données, les pipelines et les modèles de données.

D2. OLTP System's Entity-Relation Diagram

Diagramme entité-relation (ERD) présentant le schéma normalisé du système transactionnel.

D3. OLAP System's Schema Design

Conception détaillée du schéma pour le système OLAP, incluant les schémas en étoile ou en flocon, les stratégies d'agrégation et les techniques d'optimisation des requêtes.

D4. NoSQL Data Model

Une conception détaillée du schéma pour le système *NoSQL*, incluant les stratégies de gestion des données non structurées, des relations et de l'indexation.

D5. Data Pipeline Architecture

Document technique décrivant l'architecture du pipeline de données, incluant les outils, technologies et processus d'intégration et de synchronisation des données.

D6. Security and Compliance Plan

Plan détaillé décrivant les mesures de sécurité, les stratégies de conformité et les outils de surveillance à mettre en œuvre à travers l'architecture de données.

D7. Machine Learning Integration Strategy

Document décrivant l'intégration des modèles de machine learning au sein du système NoSQL, incluant l'extraction de caractéristiques, le déploiement de modèles et le suivi de la performance.

D8. SQ/NoSQL Queries

Un ensemble de requêtes SQL et NoSQL démontrant comment des questions métier clés (ex. analyse des revenus, détection de fraude, segmentation client) peuvent être répondues à l'aide des modèles de données proposés.

7. Traçabilité des exigences

7.1. Couverture des enjeux stratégiques

#	Business Objective	Business Requirements	Technical Requirements	Livrables
C1	Complex Transactional Workloads	BR1	TR1 *(volet OLTP)*, TR3[, TR6]	D1, D2, D8
C2	Advanced Analytics Requirements	BR2	TR1 *(volet OLAP)*, TR3	D1, D3, D8
C3	Handling U/S and S/S Data	BR3	TR1 *(volet NoSQL)*, TR6	D1, D4, D7, D8
C4	Data Integration Across Systems	BR4	TR2, TR4	D1, D5
C5	Security and Compliance	BR5	TR5	D1, D6

7.2. Couverture des exigences d'affaire

#	Business Requirement	Business Objective	Technical Requirements	Livrables
BR1	Intégrité transactionnelle	C1	TR1 *(volet OLTP)*, TR3	D1, D2, D8
BR2	Analytique évolutive et efficace	C2	TR1 *(volet OLAP)*, TR3	D1, D3, D8
BR3	Gestion flexible des données	C3	TR1 *(volet NoSQL)*, TR6	D1, D4, D7, D8
BR4	Intégration et cohérence des données	C4	TR2, TR4	D1, D5
BR5	Sécurité et conformité	C5	TR5	D1, D6

7.3. Couverture des exigences techniques

#	Technical Requirement	Business Objectives	Business Requirements	Livrables
TR1	Conception des modèles de données	C1, C2, C3	BR1, BR2, BR3	D1, D2, D3, D4, D8
TR2	Architecture du pipeline de données	C4	BR4	D1, D5
TR3	Évolutivité & optimisation des performances	C1, C2	BR1, BR2	D1, D2, D3, D8
TR4	Cohérence & synchronisation des données	C4	BR4	D1, D5
TR5	Sécurité & conformité	C5	BR5	D1, D6
TR6	Analytique avancée & machine learning	C3	BR3	D1, D4, D7

Références

Ressources

- [R0] Stripe Business Case