STRIPE PROJECT

0. Introduction

> *Nicolas Pichon --- AIA RNCP 38777 / BC02 / Introduction / v03 --- 2026/11/05.*

- 0.1. Contexte
- 0.2. Enoncé
  - 0.2.1. Contexte d'entreprise
  - 0.2.2. Objectifs de l'exercice
  - 0.2.3. Enjeux stratégiques
  - 0.2.4. Exigences d'affaire
  - 0.2.5. Exigences techniques
  - 0.2.6. Sources de données
  - 0.2.7. Livrables
  - 0.2.8. Traçabilité des exigences
- 0.3. Compréhension
- 0.4. Périmètre
- Références

0.1. Contexte

L'objectif de ce document est de présenter l'exercice de conception d'une architecture de données et d'intelligence artificielle pour l'entreprise *Stripe* dans le cas d'étude fictif spécifié dans [R0].

0.2. Enoncé

Reprise de l'énoncé de l'exercice d'après le *business case Stripe* [R0].

0.2.1. Contexte d'entreprise

Stripe est une entreprise de technologie financière de premier plan, fondée en 2010, et basée à San Francisco, en Californie. Elle propose une suite complète de produits pour gérer les paiements et les opérations financières des entreprises de toutes tailles. Elle accompagne des millions de marchands dans le monde entier et traite des milliards de transactions chaque année. À mesure que la société se développe, elle fait face à une complexité croissante dans la gestion de ses données réparties sur différentes plateformes, incluant les systèmes transactionnels (OLTP), les systèmes analytiques (OLAP) et les bases de données non relationnelles (NoSQL).

0.2.2. Objectifs de l'exercice

Stripe souhaite construire une infrastructure de données de pointe qui intègre de manière fluide ces différents types de systèmes afin de soutenir à la fois l'excellence opérationnelle et l'analyse avancée. L'objectif de cet exercice est de créer une architecture de données unifiée et évolutive, capable de gérer de gros volumes de données transactionnelles, de supporter des requêtes analytiques complexes, et de gérer des données non structurées pour des cas d'usage avancés tels que la détection de fraude, l'analyse du comportement client et les recommandations en temps réel.

0.2.3. Enjeux stratégiques

0.2.3.1. Synopsis

Les enjeux stratégiques de l'exercice sont les suivants :

#	Enjeu stratégique (fr)	Business Objective (en)
C1	Charges transactionnelles complexes	Complex Transactional Workloads
C2	Besoins avancés en matière d'analytique	Advanced Analytics Requirements
C3	Gestion des données non structurées et semi-structurées	Handling Unstructured and Semi-Structured Data
C4	Intégration des données entre systèmes	Data Integration Across Systems
C5	Sécurité et conformité	Security & Compliance

0.2.3.2. Descriptions détaillées

C1. Complex Transactional Workloads

Les systèmes *OLTP* de *Stripe* traitent des millions de transactions chaque jour, avec des exigences élevées en matière de disponibilité, de cohérence et de rapidité. Ces transactions incluent les paiements, les remboursements (refunds), les rétro-facturations (chargebacks) et la gestion des abonnements. L'entreprise doit s'assurer que ces systèmes sont hautement disponibles, évolutifs et capables de supporter de nouvelles fonctionnalités comme la détection de fraude en temps réel.

C2. Advanced Analytics Requirements

Stripe doit fournir une analytique robuste à ses clients et aux parties prenantes internes. Cela inclut l'analyse des revenus, la segmentation client, le reporting de conformité et le suivi de la performance des différents produits. L'entreprise a besoin d'un système *OLAP* capable de traiter des requêtes complexes efficacement, de supporter l'analyse ad hoc, et de fournir des insights quasi temps réel.

C3. Handling Unstructured and Semi-Structured Data

Stripe collecte de grandes quantités de données non structurées et semi-structurées, telles que les journaux (logs), les retours clients et les données d'interaction issues de son site web et de ses applications mobiles. Ces données sont essentielles pour construire des modèles de machine learning dédiés à la détection de fraude, à la personnalisation client et à l'analyse prédictive. L'entreprise a besoin d'une base de données *NoSQL* capable de stocker et traiter efficacement ces données, de les intégrer aux données relationnelles, et d'offrir des capacités de requêtage flexibles.

C4. Data Integration Across Systems

Intégrer les données entre les systèmes *OLTP*, *OLAP* et *NoSQL* constitue un défi majeur. *Stripe* a besoin d'une architecture de données unifiée permettant une circulation fluide des données entre ces systèmes, garantissant que les données restent cohérentes, à jour et accessibles pour les différents cas d'usage.

C5. Security & Compliance

Étant donné la nature sensible des données financières, *Stripe* doit s'assurer que son architecture de données respecte les réglementations telles que le RGPD, la norme PCI-DSS et le CCPA. L'entreprise doit également mettre en œuvre des mesures de sécurité robustes pour protéger les données au repos et en transit, gérer les contrôles d'accès, et surveiller l'utilisation des données.

0.2.4. Exigences d'affaire

0.2.4.1. Synopsis

Les exigences d'affaire de l'exercice sont les suivantes :

#	Exigence d'affaire (fr)	Business Requirement (en)
BR1	Intégrité transactionnelle	Transactional Integrity (OLTP)
BR2	Analytique évolutive et efficace	Scalable and Efficient Analytics (OLAP)
BR3	Gestion flexible des données	Flexible Data Management (NoSQL)
BR4	Intégration et cohérence des données	Data Integration Across Systems
BR5	Sécurité et conformité	Security & Compliance

0.2.4.2. Descriptions détaillées

BR1. Transactional Integrity

Les systèmes *OLTP* de *Stripe* doivent gérer de gros volumes de transactions avec une latence minimale. Le système doit respecter les propriétés ACID afin de garantir la cohérence et l'intégrité des données dans des environnements distribués. Il doit également supporter des fonctionnalités telles que les transactions multi-documents, la synchronisation des données en temps réel, et la reprise après sinistre (disaster recovery).

BR2. Scalable and Efficient Analytics

Le système *OLAP* doit supporter des requêtes complexes sur de grands ensembles de données. Il doit être capable d'agréger les données selon plusieurs dimensions, de supporter l'analyse de séries temporelles, et de gérer des jointures et sous-requêtes à grande échelle. Le système doit fournir des réponses à faible latence pour les requêtes métier critiques et supporter à la fois l'analyse historique et l'analyse quasi temps réel.

BR3. Flexible Data Management

Stripe a besoin d'un système *NoSQL* capable de gérer des types de données variés, incluant le JSON, le XML et les données binaires. Le système doit supporter une conception de schéma flexible, permettre un requêtage efficace des données imbriquées et non structurées, et s'intégrer avec les autres systèmes de données afin d'offrir une vue globale et cohérente des données.

BR4. Data Integration and Consistency

L'architecture de données doit garantir une circulation cohérente des données entre les systèmes *OLTP*, *OLAP* et *NoSQL*. *Stripe* doit mettre en œuvre des pipelines de données capables de gérer le traitement par lots (batch), les flux de données en continu (streaming), et la synchronisation en temps réel. L'architecture doit supporter les processus *ETL*/*ELT* et permettre la transformation et l'enrichissement des données.

BR5. Security and Compliance

L'architecture de données doit inclure des mesures de sécurité robustes, telles que le chiffrement, les contrôles d'accès et la journalisation d'audit. *Stripe* doit s'assurer que son stockage et son traitement des données respectent les exigences réglementaires des différentes juridictions. Le système doit supporter un reporting de conformité automatisé et une surveillance en temps réel des failles de sécurité.

0.2.5. Exigences techniques

0.2.5.1. Synopsis

Les exigences techniques de l'exercice sont les suivantes :

#	Exigence Technique (fr)	Technical Requirement (en)
TR1	Conception des modèles de données	Data Model Design (OLTP, OLAP, NoSQL)
TR2	Architecture du pipeline de données	Data Pipeline Architecture
TR3	Optimisation de l'évolutivité et des performances	Scalability and Performance Optimization
TR4	Cohérence et synchronisation des données	Data Consistency and Synchronization
TR5	Sécurité et conformité	Security & Compliance
TR6	Analytique avancée et machine learning	Advanced Analytics and Machine Learning

0.2.5.2. Descriptions détaillées

TR1. Data Model Design

Concevoir des modèles de données pour chaque type de système :

- **OLTP** : privilégier des schémas normalisés, l'intégrité transactionnelle et l'optimisation des performances.
- **OLAP** : concevoir des schémas en étoile ou en flocon pour un requêtage et une agrégation efficaces. Inclure des tables pré-agrégées pour les requêtes courantes.
- **NoSQL** : concevoir des schémas flexibles supportant les données non structurées et permettant un requêtage et une récupération de données efficaces.

TR2. Data Pipeline Architecture

Développer un *pipeline* de données intégrant les systèmes *OLTP*, *OLAP* et *NoSQL*. Le pipeline doit supporter le traitement par lots et en temps réel, ainsi que la transformation et l'enrichissement des données. Envisager l'utilisation d'outils tels qu'*Apache Kafka* pour le streaming de données en temps réel et *Apache Airflow* pour l'orchestration des processus ETL/ELT.

TR3. Scalability and Performance Optimization

S'assurer que l'architecture de données peut monter en charge horizontalement pour gérer des volumes de données croissants. Mettre en œuvre des stratégies d'indexation, de partitionnement et de mise en cache afin d'optimiser les performances sur l'ensemble des systèmes. Envisager l'utilisation de bases de données distribuées et du sharding pour garantir une haute disponibilité.

TR4. Data Consistency and Synchronization

Mettre en œuvre des mécanismes garantissant la cohérence des données entre les systèmes *OLTP*, *OLAP* et *NoSQL*. Envisager des modèles de cohérence à terme (*eventual consistency*) lorsque cela est pertinent, et mettre en œuvre des stratégies de résolution de conflits pour les données distribuées. Utiliser des techniques de *CDC* (*Change Data Capture*) pour maintenir les données synchronisées en temps réel.

TR5. Security and Compliance

Concevoir un cadre de sécurité incluant le chiffrement des données, le contrôle d'accès basé sur les rôles (RBAC) et la journalisation d'audit. S'assurer que l'architecture respecte les réglementations en vigueur (ex. RGPD, PCI-DSS). Mettre en œuvre des contrôles de conformité automatisés et des fonctionnalités de reporting.

TR6. Advanced Analytics and Machine Learning

Intégrer des modèles de *machine learning* au sein du système *NoSQL* pour la détection de fraude en temps réel et la personnalisation client. S'assurer que le pipeline de données supporte l'extraction de caractéristiques (*feature extraction*) et le déploiement de modèles. Prévoir des mécanismes de suivi de la performance des modèles et de mise à jour.

0.2.6. Sources de données

0.2.6.1. Synopsis

#	Source de données (fr)	Data Source (en)
DS1	Données transactionnelles	Transactional Data (OLTP)
DS2	Données analytiques	Analytical Data (OLAP)
DS3	Données non structurées et semi-structurées	Unstructured and Semi-Structured Data (NoSQL)
DS4	Données de référence	Reference Data

0.2.6.2. Descriptions détaillées

DS1. Transactional Data

Capturent l'ensemble des transactions financières traitées par *Stripe*. Champs inclus :

- Identifiant de transaction
- Identifiant marchand
- Identifiant client
- Montant de la transaction
- Devise
- Moyen de paiement
- Date et heure de la transaction
- Localisation (géolocalisation par IP)
- Type d'appareil (mobile, ordinateur, etc.)
- Statut (réussie, échouée, remboursée)
- Indicateurs de fraude (ex. scores d'anomalie)

DS2. Analytical Data

Données agrégées et historiques utilisées pour le reporting et l'analyse. Champs inclus :

- Indicateurs de revenus (journaliers, hebdomadaires, mensuels)
- Données de segmentation client
- Indicateurs de performance produit
- Données d'analyse de la fraude
- Journaux de conformité et d'audit

DS3. U/S and S/S Data

Données collectées depuis diverses sources, telles que les journaux, les interactions clients et les données générées par des machines. Champs inclus :

- Données de journaux (journaux d'erreurs, journaux d'accès)
- Données d'interaction utilisateur (données de clics, données de session)
- Caractéristiques (features) de machine learning (données d'entrée des modèles)
- Retours clients (avis, réponses aux enquêtes)

DS4. Reference Data

Données statiques ou évoluant lentement, utilisées à travers l'ensemble des systèmes :

- Codes pays et région
- Taux de change des devises
- Informations sur les marchands
- Catalogues produits

0.2.7. Livrables

0.2.7.1. Synopsis

#	Livrable (fr)	Deliverable (en)
D1	Diagramme d'architecture de données complet	Comprehensive Data Architecture Diagram
D2	ERD pour le système OLTP	ERD for OLTP System
D3	Conception du schéma pour le système OLAP	Schema Design for OLAP System
D4	Modèle de données NoSQL	NoSQL Data Model
D5	Architecture du pipeline de données	Data Pipeline Architecture
D6	Plan de sécurité et de conformité	Security and Compliance Plan
D7	Stratégie d'intégration du machine learning	Machine Learning Integration Strategy
D8	Requêtes SQL et NoSQL	SQL and NoSQL Queries

0.2.7.2. Descriptions détaillées

D1. Data Architecture Diagram

Diagramme détaillé montrant l'intégration des systèmes de données (*OLTP*, *OLAP*, *NoSQL*), incluant les flux de données, les pipelines et les modèles de données.

D2. OLTP System's Entity-Relation Diagram

Diagramme entité-relation (ERD) présentant le schéma normalisé du système transactionnel.

D3. OLAP System's Schema Design

Conception détaillée du schéma pour le système OLAP, incluant les schémas en étoile ou en flocon, les stratégies d'agrégation et les techniques d'optimisation des requêtes.

D4. NoSQL Data Model

Une conception détaillée du schéma pour le système *NoSQL*, incluant les stratégies de gestion des données non structurées, des relations et de l'indexation.

D5. Data Pipeline Architecture

Document technique décrivant l'architecture du pipeline de données, incluant les outils, technologies et processus d'intégration et de synchronisation des données.

D6. Security and Compliance Plan

Plan détaillé décrivant les mesures de sécurité, les stratégies de conformité et les outils de surveillance à mettre en œuvre à travers l'architecture de données.

D7. Machine Learning Integration Strategy

Document décrivant l'intégration des modèles de machine learning au sein du système NoSQL, incluant l'extraction de caractéristiques, le déploiement de modèles et le suivi de la performance.

D8. SQL/NoSQL Queries

Un ensemble de requêtes SQL et NoSQL démontrant comment des questions métier clés (ex. analyse des revenus, détection de fraude, segmentation client) peuvent être répondues à l'aide des modèles de données proposés.

0.2.8. Traçabilité des exigences

0.2.8.1. Couverture des enjeux stratégiques par les exigences d'affaire

#	Business Objective	Business Requirements
C1	Complex Transactional Workloads	BR1
C2	Advanced Analytics Requirements	BR2
C3	Handling U/S and S/S Data	BR3
C4	Data Integration Across Systems	BR4
C5	Security and Compliance	BR5

0.2.8.2. Couverture des exigences d'affaire par les exigences technique

#	Business Requirement	Technical Requirements	Livrables
BR1	Intégrité transactionnelle	TR1/OLTP, TR3	D1, D2, D8
BR2	Analytique évolutive et efficace	TR1/OLAP, TR3	D1, D3, D8
BR3	Gestion flexible des données	TR1/NoSQL, TR6	D1, D4, D7, D8
BR4	Intégration et cohérence des données	TR2, TR4	D1, D5
BR5	Sécurité et conformité	TR5	D1, D6

0.2.8.3. Traçabilité des exigences techniques

#	Technical Requirement	Business Requirements	Livrables
TR1	Conception des modèles de données	BR1, BR2, BR3	D1, D2, D3, D4, D8
TR2	Architecture du pipeline de données	BR4	D1, D5
TR3	Évolutivité & optimisation des performances	BR1, BR2	D1, D2, D3, D8
TR4	Cohérence & synchronisation des données	BR4	D1, D5
TR5	Sécurité & conformité	BR5	D1, D6
TR6	Analytique avancée & machine learning	BR3	D1, D4, D7

0.3. Compréhension

Compréhension du métier de *Stripe* et de son rôle dans la chaîne de paiement (d'après des sources externes) :

- métiers et fonctionnements,
- produits, services et revenus,
- scénario de paiement typique.

0.3.1. Métiers et fonctionnements de Stripe

Stripe est une entreprise de services financiers et logiciels. Elle fournit l'infrastructure de paiement et de monétisation à des millions d'entreprises en ligne, des start-ups aux grands groupes, en leur permettant d'accepter des paiements, de gérer des abonnements, de verser des fonds à des tiers, et d'automatiser des aspects fiscaux et de conformité.

Stripe est souvent qualifiée de « tuyauterie financière d'Internet » : elle abstrait la complexité des réseaux bancaires, des schémas de cartes, des réglementations et des méthodes de paiement locales derrière des API et des interfaces simples pour les développeurs et les équipes produit.

0.3.2. Services et produits

0.3.2.1. Principaux services

- **Traitement du paiement (cœur de métier) :**
  - autorisation, capture, prélèvement carte/virement/wallet, dans des dizaines de devises et méthodes de paiement.
- **Gestion des remboursements et litiges**
- **Détection de fraude :**
  - *Stripe Radar* : outils de détection de fraude basés sur le machine learning, règles personnalisables, *3D-Secure*, etc.
- **Facturation récurrente & abonnements :**
  - *Stripe Billing* : gestion d'abonnements récurrents, facturation à l'usage, essais gratuits, upgrades/downgrades, etc.
  - *Stripe Invoicing* : Émission et suivi de factures, relances automatiques, gestion des impayés.
- **Reversement aux marchands (*payouts*) :**
  - Versements vers des comptes bancaires dans de nombreux pays, y compris pour des bénéficiaires tiers.

0.3.2.2. Produits annexes

- *Stripe Connect* (marketplaces, paiements multi-parties),
- *Stripe Treasury* (comptes bancaires intégrés),
- *Stripe Issuing* (cartes),
- *Stripe Capital* (financement des marchands),
- *Sigma*, *Data Pipeline* (reporting & data)

0.3.2.3. Intérêt du marchand

Le marchand s'affranchit des démarches pour obtenir l'agrément réglementaire d'établissement de paiement et des négociations avec les réseaux de cartes et les banques acquéreuses. *Stripe* absorbe toute cette complexité réglementaire et technique derrière une API et le marchand n'a qu'à s'intégrer.

0.3.3. Revenus

Stripe tire principalement ses revenus des sources suivantes :

- Une commission sur chaque transaction (ex. typiquement 2,9% + 0,30 $ pour les paiements en ligne par carte aux États-Unis ; tarifs variables selon pays, volume, méthode).
- Des frais additionnels pour :
  - Paiements internationaux, conversion de devises.
  - Gestion des litiges / remboursements (ex. 15 $ par litige, remboursés si gagné).
  - Payouts instantanés (ex. +1% par transfert).
- Des produits logiciels à forte marge : *Billing*, Tax, Radar avancé, Issuing, Treasury, Capital, etc.

Contrairement à certains *PSP* traditionnels, *Stripe* applique généralement une tarification « flat-rate » simple sur son plan standard, sans frais mensuels fixes pour la plupart des petits marchands.

0.3.4. Flux de paiement

0.3.4.1. *Stripe* est un « payment facilitator »

Techniquement, *Stripe* agit comme un *payment facilitator* :

- Elle dispose d'un *compte marchand maître* auprès d'une banque acquéreuse.
- Les entreprises clientes sont enregistrées comme *sous-marchands* sous ce compte maître.
- Les transactions des sous-marchands remontent d'abord vers l'infrastructure de *Stripe*, qui gère l'autorisation, le règlement (*settlement*), la répartition des fonds et les risques.
- *Stripe* reverse ensuite les fonds nets aux marchands (*payout*), selon un calendrier prédéfini.

Les fonds passent donc par les infrastructures suivantes :
- Le réseau de paiement → compte bancaire dédié de *Stripe* → compte du marchand chez *Stripe* → virement vers le compte bancaire du marchand (*payout*).
- Les frais sont prélevés avant le *payout*, donc le montant reçu par le marchand est net des commissions et éventuels ajustements (remboursements, réserves, etc.).

0.3.4.2. Rôle de *Stripe* : autorisation, collecte, reversement

Le flux typique d'une transaction passant par *Stripe* est le suivant :

1. **Autorisation** :
   - Le client paie (carte, virement, etc.) ;
   - La demande transite par *Stripe*, par le réseau de carte, jusqu'à la banque émettrice ;
   - La banque autorise ou refuse en < 1 seconde.
2. **Settlement (règlement)**
   - Une fois que la transaction est autorisée, elle est « capturée ».
   - Les fonds sont transférés de la banque du client vers le compte dédié de *Stripe* (via la banque acquéreuse et les schémas).
   - *Stripe* crédite alors le solde *Stripe* du marchand (balance interne), net de ses frais.
3. **Payout (reversement au marchand)**
   - Par défaut, *Stripe* regroupe les transactions disponibles en *payouts cumulés périodiques* et les envoie vers le compte bancaire lié du marchand (via ACH, SEPA, etc.).
   - Aux États-Unis, le délai standard de reversement est souvent de 2 jours ouvrés après la transaction (peut varier selon le pays, le risque, l'ancienneté du compte).
   - Pour les nouveaux comptes ou activités jugées plus risquées, *Stripe* peut appliquer des délais plus longs (7, 14 jours, voire plus) ou des réserves.

0.4. Périmètre

Périmètre fonctionnel et architectural de l'exercice :

- couverture fonctionnelle (quelle partie du métier de *Stripe* est couverte?),
- cas d'utilisation pris en compte,
- limites.

0.4.1. Couverture fonctionnelle

Le *business case Stripe* [R0] limite implicitement la couverture fonctionnelle de l'exercice à la gestion des transactions du point de vue du client. Le scoring et la détection de fraude au paiement sont inclus dans ce périmètre.

0.4.2. Cas d'utilisation

Cas d'utilisation pris en compte dans l'exercice :

- enregistrement des marchands, catalogues et plans tarifaires,
- enregistrement des clients, abonnements, moyens de paiement,
- enregistrement des transactions, remboursements, et rétro-facturations (litiges),
- scoring de fraude au paiement,
- alerting de sécurité,
- reporting de conformité.

0.4.3. Limites

- Limites induites par le périmètre précédent :
  - pas de dépôts ni de reversement au marchand,
  - pas de produits ni de services annexes ;
- Intégration du machine learning :
  - étude de cas des modèles de scoring de fraude,
  - description succincte des modèles de personnalisation et d'analyse prédictive (exigés dans les spécification du *business case* [R0] mais non traités) ;
- Scalabilité horizontale :
  - OLTP : l'aspect *distribué* de l'architecture de données n'est pas pris en compte *dans le modèle transactionnel* :
    - SGBD centralisé (cible : *PostgreSQL*),
    - pas de partitionnement,
    - pas de sharding,
    - pas de mise en cache.
- Mise en oeuvre :
  - les architectures, pipelines et modèles proposés ne sont pas vérifiés par une implémentation.

Références

Ressources

- [R0] Stripe Business Case