Dossier de référence

Projet Stripe · D0 à D8.3, annexes et diagrammes — un à trois écrans par livrable

11 livrables

D0 · D1 · D2 · D3 · D4
D5 · D6 · D7 · D8.1–8.3

10 annexes

MCD, DBML, notes de conception,
reprise, Kimball, outillage…

30+ diagrammes

architecture, ERD, étoiles,
collections, pipeline, ML

Usage

support de secours :
une question, un écran

Carte du dossier

20 écrans

Écran	Livrable	Contenu	Version
3	**D0 - Introduction**	Énoncé, enjeux, exigences, périmètre	v05
4-5	**D1 - Architecture de données**	Sous-systèmes, flux, technologies	v33
6-7	**D2 - Diagrammes ERD (OLTP)**	Groupes fonctionnels, MCD, reprise	v36
8-9	**D3 - Conception OLAP**	Six étoiles, agrégats, optimisation	v22
10-11	**D4 - Modèle NoSQL**	Cinq collections, sharding, intégration	v09
12-13	**D5 - Pipeline de données**	Cinq couches, garanties, conformité	v10
14-15	**D6 - Sécurité & conformité**	Chiffrement, RBAC, RGPD, PCI-DSS	v04
16-17	**D7 - Intégration du ML**	Scoring de fraude, features, monitoring	v11
18	**D8.1 / D8.2 / D8.3 - Requêtes**	SQL transactionnel, analytique, NoSQL	v36 / v22 / v09
19	**Annexes**	Les dix annexes et ce qu'elles portent	—
20	**Limites assumées**	Ce que le dossier ne traite pas, et pourquoi	—

Les numéros d'écran correspondent au pied de page. Les versions sont celles du dossier au 4 novembre 2026.

D0 Introduction

L'énoncé du business case, sa traduction en enjeux et en exigences, et le périmètre que le dossier se donne.

C1 — Transactionnel

Charges transactionnelles complexes

C2 — Analytique

Besoins analytiques avancés

C3 — Non structuré

Données semi et non structurées

C4 — Intégration

Intégration entre systèmes

C5 — Conformité

Sécurité et conformité

Six exigences techniques

- TR1 — Conception des modèles OLTP / OLAP / NoSQL
- TR2 — Architecture du pipeline de données
- TR3 — Évolutivité et optimisation des performances
- TR4 — Cohérence et synchronisation des données
- TR5 — Sécurité et conformité
- TR6 — Analytique avancée et machine learning

Périmètre retenu

- La transaction du point de vue du client — scoring de fraude inclus
- Marchands, catalogues, plans tarifaires ; clients, abonnements, moyens de paiement
- Transactions, remboursements, rétro-facturations
- Alerting de sécurité et reporting de conformité
- Hors périmètre : dépôts et reversements au marchand, produits annexes

D1 Architecture de données — vue d'ensemble

Principe directeur. Le chemin transactionnel n'est jamais ralenti par la sécurité, la conformité, l'analytique ou la détection de fraude. Tous les flux sortants de l'OLTP sont asynchrones : pas de trigger synchrone, exploitation du CDC natif.

Sous-système	Rôle	Technologie
Couche applicative	Centralise les flux d'entrée (paiement, consultation, administration)	—
OLTP	Source de vérité transactionnelle, schéma normalisé	PostgreSQL
Service de scoring	Autorise, bloque ou suspend la transaction en moins de 100 ms	—
Bus d'évènements	Redistribue les évènements applicatifs et le CDC, en continu	Kafka
NoSQL	Documents : logs, sessions, features, feedbacks, cache marchand	MongoDB
Orchestrateur	Planifie et exécute l'extraction vers l'entrepôt analytique	Airflow
OLAP	Données analytiques en schéma étoile	Snowflake
Alerte sécurité · Reporting · Accès direct	Les trois sous-systèmes finaux qui servent les consommateurs	—

Quatre vues détaillent cette architecture : le cœur métier (1-2), le scoring de fraude (1-3), la sécurité et la conformité (1-4), et la séquence de scoring (2). Les quatorze diagrammes de modèles — transactionnel, analytique, NoSQL — complètent l'ensemble.

D1 Architecture de données — flux et diagrammes

Vue 1-2 — Cœur métier

Transactions, marchands, clients. Exclut fraude, sécurité et ML.

Vue 1-3 — Scoring de fraude

Features, cache marchand, décision, boucle de retour vers l'OLTP.

Vue 1-4 — Sécurité & conformité

Journaux d'accès et d'écriture, incidents, demandes de droits.

Flux	Trajet	Nature
1	Acteurs → couche applicative	Synchrone
2	Applications → OLTP (cœur fonctionnel, demandes de droits)	Synchrone
2B	Topics → OLTP : logs, incidents, fraud scores	Asynchrone continu
3	Applications et CDC OLTP → topics Kafka	Asynchrone continu
4	Topics → NoSQL : logs, sessions, features, cache marchand	Asynchrone continu (Flink)
5	Topics et Change Streams → staging OLAP	Asynchrone continu
6	Airflow déclenche dbt + staging → OLAP Core	Batch planifié
7	OLAP, NoSQL, reporting → consommateurs finaux	Restitution
8 / 8R	NoSQL → scoring (< 10 ms) ; scoring → applications (< 100 ms)	Temps réel strict

D2 Diagrammes entité-association (OLTP)

v36 · 4 annexes

Le modèle transactionnel est organisé en cinq groupes fonctionnels, ordonnés par leurs dépendances. Une flèche de A vers B signifie que des tables de A référencent des tables de B.

Références

Tables d'énumération autonomes, référencées par tous les autres groupes.

Marchands

Marchands, produits, plans tarifaires. Ne dépend que des références.

Clients

Clients, abonnements, moyens de paiement. S'appuie sur les marchands.

Transactions

Transactions, remboursements, litiges, fraude. Dépend des deux précédents.

Sécurité & conformité

Journaux, consentements, incidents, demandes de droits.

Étiquetage des tables

- ★ entité métier principale · ⊞ entité secondaire
- ☷ énumération · ▤journal
- 🔒 immuable : ni modifiable ni supprimable après création
- ✖ ne peut pas être journalisée

Décision structurante

- Pas de partitionnement : Transaction, DataAccessLog, ChangeAuditLog et FraudScoringLog restent des tables ordinaires à clé primaire simple
- Les tables dépendantes de Transaction ne portent aucune colonne de partition
- Conséquence assumée : la scalabilité horizontale de l'OLTP est hors sujet (D0 §0.4.3)

D2 OLTP — les quatre annexes

D2-A · D2-B · D2-C · D2-D

Annexe	Titre	Ce qu'elle porte
D2-A	Modèle conceptuel (MCD)	Diagrammes conceptuels, dictionnaire des entités et des associations, règles de gestion, règles de passage au modèle logique, et les écarts conceptuel/logique
D2-B	Modèle physique (DBML)	Le schéma physique complet : tables, colonnes, types, contraintes, index. C'est la référence citée par D3, D6 et D8.1
D2-C	Notes de conception	Principes de conception, justification du modèle de tarification, justification du modèle de sécurité et conformité, et passage à l'échelle (indexation, partitionnement, sharding)
D2-D	Réplication, bascule et reprise	Stratégie de réplication, procédure de bascule (failover), reprise après sinistre, et la distinction sauvegarde / réplication

À retenir. D2-A n'est pas une redite du modèle physique : il documente le raisonnement conceptuel et, surtout, les endroits où le modèle logique s'écarte du modèle conceptuel — c'est là que les choix de conception se discutent.

D3 Conception du système analytique (OLAP)

v22 · 3 annexes

Schéma en étoile, pas en flocon : la dénormalisation des dimensions coûte en stockage et gagne en temps de requête. Aucune dimension n'en référence une autre — seules les tables de faits portent des clés étrangères.

Processus	Table de faits	Grain	Sert
P1 — Revenus	FactTransaction	La transaction	Revenu net, commission, top produits
P2 — Fraudes	FactFraudEvent	L'évaluation de risque	Taux de fraude par niveau évalué
P3 — Abonnements	FactSubscriptionSnapshot	L'instantané périodique	Revenu récurrent, risque de désabonnement
P4 — Accès	FactAuditEvent	L'accès ou l'écriture	Tentatives non autorisées, historique
P5 — Droits	FactDataSubjectRequest	La demande	Respect des délais RGPD / CCPA
P6 — Incidents	FactSecurityIncident	L'incident	Délai de notification par sévérité

Les six étoiles ne partagent aucune ligne — seulement des dimensions conformées (DimDate, DimMerchant, DimCustomer, DimGeography). La matrice de bus est en D3-A §2.A.6.

D3 OLAP — agrégats, optimisation, annexes

Principe constant. Le fait atomique reste au grain le plus fin ; les agrégats sont des tables séparées, calculées. Le fait référence toujours une dimension par clé pour permettre n'importe quel angle d'analyse ; l'agrégat garde parfois l'attribut en clair, pour répondre vite à une question déjà posée.

Sept tables d'agrégats

- Revenu : jour × marchand — et mois × marchand × pays
- Fraude : jour × marchand — alerting
- Abonnements : jour × marchand × produit
- Conformité : jour × marchand
- Droits : mois × marchand × réglementation × type
- Incidents : mois × marchand × sévérité

Huit techniques d'optimisation

- Clés de substitution entières ; DimDate précalculée
- Partitionnement par date_key
- Stockage orienté colonnes ; index ciblés
- Diffusion des dimensions
- Taux de change de référence fixe — conversion reproductible
- Sécurité RLS jusque dans l'entrepôt

Annexes — D3-A : les quatre étapes de la méthode Kimball (processus, grains, dimensions, faits) puis la matrice de bus. D3-B : le schéma analytique physique complet. D3-C : conversion de devise, fuseaux horaires, et les règles de transformation ETL table par table.

D4 Modèle de données NoSQL

En relationnel, on modélise le domaine puis on écrit les requêtes. En document, on part des requêtes : chaque collection est conçue pour qu'une lecture typique n'implique aucune jointure.

Collection	Écriture	Lecture	Profil
event_logs	Continue, flux massif	Par fenêtre temporelle	Dominé par l'écriture
user_sessions	Unitaire, à chaque interaction	Session entière, en une fois	Dominé par l'écriture
ml_features	Recalcul périodique par entité	Immédiate, par le modèle	Équilibré — lecture critique en latence
customer_feedback	Occasionnelle	Par client ou agrégée	Dominé par la lecture agrégée
merchant_config	Quasi jamais	Très fréquente, par clé unique	Quasi exclusivement lu

Trois principes de conception

Modéliser selon les accès — un motif d'accès mal identifié produit un schéma qu'aucun index ne corrigera ensuite. **Schéma flexible mais contrôlé** — validation JSON Schema sur les champs critiques, pour éviter la dérive silencieuse. **Imbriquer par défaut, référencer exceptionnellement** — on ne référence que si l'entité est partagée, de taille non bornée, ou de cycle de vie indépendant.

D4 NoSQL — sharding, intégration, cohérence

Collection	Clé de sharding	Justification
event_logs	{ service, timestamp }	Écriture répartie par service émetteur, lecture par fenêtre temporelle
user_sessions	{ merchant_id, started_at }	Cloisonnement marchand préservé
ml_features	{ _id: hashed }	Répartition uniforme, accès par clé unique, sans motif marchand dominant
customer_feedback	merchant_id	Lecture dominante par marchand
merchant_config	Non shardée	Volume trop faible

Intégration aux deux autres systèmes

- OLTP → NoSQL : le CDC alimente Kafka ; un agent actualise merchant_config et déclenche le recalcul des ml_features
- NoSQL → OLAP : les Change Streams alimentent Airflow, qui agrège par lots nocturnes — seuls les agrégats partent vers l'entrepôt

Cohérence différenciée

- Cohérence à terme acceptée pour les journaux et les sessions : quelques secondes sans conséquence
- Contrainte maximale sur ml_features : readConcern « majority » en lecture, parce que la décision de fraude en dépend

D5 Architecture du pipeline de données

v10 · 2 annexes

Principe. La base OLTP est la source de vérité ; les autres systèmes en dérivent. Aucun consommateur n'écrit directement dans l'OLTP — à une exception près : la décision de fraude, seule boucle de retour du système.

#	Couche	Rôle	Technologies
1	**Sources**	Production des évènements	Checkout, API marchands, apps web et mobile, réseaux de cartes
2	**Capture opérationnelle**	Vérité transactionnelle	PostgreSQL
3	**Redistribution**	Diffusion des évènements	Kafka, Debezium, Schema Registry
4	**Stockages analytiques**	Persistance spécialisée	Snowflake, MongoDB, magasin de features
5	**Consommateurs**	Restitution et décision	Tableaux de bord, reporting, scoring de fraude
—	**Transverse**	Sécurité et conformité	TLS, chiffrement, RLS, audit, rétention

Deux types de sorties : des sorties analytiques a posteriori — revenus, segmentation, fraude, sécurité, conformité — et une sortie opérationnelle, la décision d'autoriser ou de bloquer un paiement, en quelques millisecondes.

D5 Pipeline — garanties, conformité, outillage

v10 · §D5.5 à §D5.11

Garanties de transport

- Ordre garanti par clé de partition
- Rejeu possible depuis n'importe quel offset — un consommateur défaillant reprend sans perte
- Livraison au moins une fois : un message peut arriver deux fois, jamais zéro — d'où l'idempotence exigée des consommateurs

Cohérence et reprise

- Idempotence des écritures (§D5.7.1)
- Modèles de cohérence différenciés par flux (§D5.7.2)
- Résolution de conflits (§D5.7.3)
- Reprise et rattrapage après incident (§D5.7.4)

Couche transverse — conformité	Mécanisme
Protection à l'entrée	Filtrage et masquage avant que la donnée n'entre dans le pipeline
Gouvernance en continu	Contrôles permanents sur les flux, pas seulement sur les stockages
Droit à l'effacement	Concilie l'effacement RGPD avec l'immuabilité des journaux d'audit et des topics non compactés
Restitution	Réponse aux demandes d'accès et de portabilité
Alerting temps réel	Détection sur les journaux d'audit, par traitement de flux

Annexes — D5-A : justification outil par outil (Debezium, Schema Registry, Flink, dbt, Snowflake, Prometheus/Grafana, Great Expectations). D5-B : les deux magasins de features, le risque de décalage entraînement/service, et l'orchestration centralisée qui le résout.

D6

Plan de sécurité et de conformité

v04 · §D6.2 à §D6.4

Chiffrement

- TLS 1.2 minimum partout, sans exception — y compris en réseau privé interne
- Chiffrement natif au repos sur les trois systèmes, sauvegardes comprises
- Clés en KMS centralisé, rotation, séparation des responsabilités

Contrôle des accès

- RBAC : les privilèges vont aux rôles, jamais aux individus
- Rôles alignés sur la typologie AuditActorType du modèle physique
- RLS sur les données de paiement, jusque dans l'entrepôt

Journalisation d'audit

- Journaux en écriture seule : UPDATE et DELETE retirés, même aux administrateurs
- Les écritures sont répliquées depuis le CDC
- DataAccessLog a son propre mécanisme : le CDC ne voit pas les SELECT

PCI-DSS — quatre mesures actées

- Ne jamais conserver le PAN dans le périmètre du système — seuls les quatre derniers chiffres sont stockés. C'est une décision de réduction de périmètre.
- Chiffrer systématiquement les données, au repos et en transit.
- Contrôler les accès ligne par ligne sur Transaction, PaymentMethod, Refund et Chargeback.
- Journaliser tous les accès à ces mêmes tables dans DataAccessLog.

D6 RGPD, incidents et automatisation du reporting

Obligation RGPD / CCPA	Mécanisme dans le modèle
Consentement	ConsentRecord en écriture seule : un retrait crée une nouvelle ligne, l'historique n'est jamais effacé. Le consentement est rattaché au marchand, pas à Stripe
Consultation et modification	DataSubjectRequest porte le délai légal réel selon le cadre applicable — 30 jours RGPD, 45 jours CCPA
Indicateur de conformité	FactDataSubjectRequest.is_within_deadline est l'indicateur central du rapport
Droit à l'effacement	Stratégie complète en D5 §D5.9.3 — conciliation avec l'immuabilité des journaux et des topics Kafka
Minimisation	TTL sur les documents bruts de user_sessions : le clickstream expire après agrégation vers l'OLAP

Cycle de vie d'un incident de sécurité

open → investigating → contained → closed

detected_at horodate le déclenchement du délai légal. notified_at doit être renseigné avant l'échéance — 72 heures pour le RGPD. Un incident clos sans notification alors que des données personnelles étaient en jeu doit être rouvert.

D7 Stratégie d'intégration du machine learning

v11 · 6 diagrammes

Le cas traité en profondeur est le scoring de fraude. La personnalisation client et l'analytique prédictive sont décrites succinctement — exigées par le business case mais hors périmètre d'étude (D0 §0.4.3).

2-1 — Vue d'ensemble

Le cycle complet : entraînement, évaluation, déploiement, monitoring, réentraînement.

2-2-a — Datasets

Comment le registre de datasets est alimenté et par qui il est lu.

2-2-b — Production

Le chemin vif : déploiement, inférence, journalisation.

2-2-c — Monitoring

Dérive de performance, dérive de données, déclenchement du réentraînement.

La détection de fraude dans le flux de paiement

- L'application transmet la demande de transaction, qui arrive dans l'OLTP.
- Le consommateur CDC — WAL puis Debezium — publie la transaction dans Kafka.
- Le service de scoring lit les features et la configuration marchand dans MongoDB, en moins de 10 ms.
- Il rend sa décision — autoriser, bloquer, suspendre — en moins de 100 ms, et la renvoie à l'application.
- Le score est publié dans le topic fraud, d'où il repart vers l'OLTP (FraudScore) et vers le staging analytique.

D7 ML — features, déploiement, monitoring

v11 · §D7.3.4 à §D7.3.10

Features

- Deux magasins : un online à faible latence, un offline pour l'entraînement
- Risque central : le décalage entraînement / service — la même feature calculée différemment des deux côtés
- La réponse est l'orchestration centralisée du calcul (D5-B)

Déploiement

- Le candidat est challengé contre le modèle en production avant toute bascule
- Le déploiement est une étape distincte et versionnée, pas un effet de bord
- Chaque inférence est journalisée — c'est ce qui rend le monitoring possible

Monitoring

- Dérive de performance : le modèle se dégrade, les données n'ont pas changé
- Dérive de données : la distribution d'entrée s'éloigne de l'entraînement
- La détection déclenche le réentraînement, qui reboucle sur le registre

Les deux autres cas d'usage, décrits et non traités

La personnalisation client (§D7.4.1) et l'analytique prédictive (§D7.4.2) sont exigées par le business case. Le dossier les décrit et montre où elles se brancheraient dans l'architecture — les mêmes features, le même registre, le même cycle — mais ne les conçoit pas. C'est une limite déclarée, pas un oubli.

D8 Exemples de requêtes SQL et NoSQL

D8.1 v36 · D8.2 v22 · D8.3 v09

Document	Système	Ce qu'il démontre
D8.1 — Requêtes OLTP	PostgreSQL	Lire une transaction · dernières transactions d'un client · enregistrer un paiement de façon idempotente · abonnements à prélever · demandes de droits proches de l'échéance · historique des accès aux données d'un client
D8.2 — Requêtes OLAP	Snowflake	Deux requêtes par processus métier, P1 à P6 : revenus nets et commission, top produits, risque de fraude, revenu récurrent, désabonnement, accès non autorisés, respect des délais légaux, incidents — plus deux requêtes d'agrégats croisés
D8.3 — Requêtes NoSQL	MongoDB	Deux requêtes par collection : erreurs récentes d'un service, parcours d'une transaction, historique de sessions, lecture d'inférence sur le chemin critique, alerting fraude, avis d'un marchand, recherche plein texte, lecture du cache avant scoring

Le choix des requêtes n'est pas décoratif. Chacune correspond à une question que le modèle devait savoir servir : D8.2 suit exactement les six processus métiers de D3, et D8.3 suit exactement les cinq collections de D4. Une requête qui n'aurait pas de modèle derrière elle, ou un modèle qu'aucune requête n'interroge, serait un défaut de conception.

Les dix annexes

et ce qu'elles portent

Réf.	Titre	Rattachée à	Apport propre
D2-A	Modèle conceptuel (MCD)	D2	Dictionnaires, règles de gestion, écarts conceptuel/logique
D2-B	Modèle physique (DBML)	D2	Schéma transactionnel complet — référence de D3, D6, D8.1
D2-C	Notes de conception	D2	Tarification, sécurité, indexation et passage à l'échelle
D2-D	Réplication et reprise	D2	Bascule, reprise après sinistre, sauvegarde ≠ réplication
D3-A	Analyse Kimball	D3	Processus, grains, dimensions, faits, matrice de bus
D3-B	Modèle physique (DBML)	D3	Faits, dimensions et agrégats analytiques
D3-C	Conventions et transformations	D3	Devises, fuseaux horaires, règles ETL table par table
D4-A	Justification du modèle de stockage	D4	Pourquoi le document, et pas les autres familles NoSQL
D5-A	Justification des outils	D5	Debezium, Schema Registry, Flink, dbt, Snowflake, supervision, qualité
D5-B	Notes sur le magasin de features	D5	Deux magasins, décalage entraînement/service, orchestration

Ce que le dossier ne traite pas — et pourquoi

Les limites ci-dessous sont déclarées dans D0 §0.4.3. Les énoncer est un choix de méthode : un périmètre tenu vaut mieux qu'un périmètre affiché et non traité.

Scalabilité horizontale de l'OLTP

SGBD centralisé. Pas de partitionnement, pas de sharding, pas de mise en cache dans le modèle transactionnel. Le reste de l'architecture, lui, est conçu pour répartir la charge.

Volumétrie et dimensionnement

Aucun chiffre de volumétrie, de débit ou de taille de cluster n'est posé. Les choix sont qualitatifs et argumentés par les motifs d'accès, pas par une capacité cible.

Mise en œuvre

Les architectures, pipelines et modèles ne sont pas vérifiés par une implémentation. Ce sont des propositions de conception, pas un système livré.

Données non structurées

Seul le JSON est pris en compte dans le NoSQL : ni XML, ni binaire.

Machine learning

Étude de cas complète sur le scoring de fraude. Personnalisation et analytique prédictive décrites, non conçues.

Métier

Pas de dépôts ni de reversements au marchand, pas de produits ni de services annexes — conséquence du périmètre fonctionnel du business case.