Questions probables

Projet Stripe · Huit questions que ce dossier appelle, et ce que les documents permettent de répondre

Une question, un écran

Chaque écran porte la réponse en une phrase, puis l'appui, puis la référence exacte.

Lire la phrase d'abord

Elle suffit dans la plupart des cas. Le reste n'est là que si on creuse.

Deux questions difficiles

Q4 (panne de Kafka) et Q8 (volumétrie) : les seules où la réponse concède quelque chose.

Les huit questions

9 écrans

Écran	Question	Angle de la réponse
3	**Quelles sont les cinq couches du pipeline ?**	Cinq stratifiées, plus une transverse
4	**Pourquoi trois bases et pas une ?**	Trois régimes de temps incompatibles
5–6	**Comment garantissez-vous la cohérence ?**	Forte où il le faut, à terme ailleurs — et réconciliée tous les jours
7	**Et si Kafka tombe ?**	Le paiement continue ; le reste se rattrape par rejeu
8	**Pourquoi le reporting réglementaire ne passe pas par l'OLAP ?**	Valeur probante et délai opposable
9	**Le droit à l'effacement sur des journaux immuables ?**	Conserver les faits, effacer l'identité
10	**Le scoring est-il réentraîné automatiquement ?**	Oui — parce que la fraude est adversariale
11	**Quelle volumétrie ?**	Aucune : limite déclarée, pas un oubli

Les deux questions que je placerais moi-même si elles ne viennent pas : Q3 (la cohérence) et Q6 (le droit à l'effacement). Ce sont les deux endroits où le dossier a tranché un vrai conflit.

Q1 Quelles sont les cinq couches du pipeline ?

En une phrase. Cinq couches stratifiées, des sources aux consommateurs — plus une sixième, transverse, qui s'applique aux cinq.

#	Couche	Rôle	Technologies
1	**Sources**	Production des évènements	Checkout, API marchands, apps web et mobile, réseaux de cartes
2	**Capture opérationnelle**	Vérité transactionnelle	PostgreSQL
3	**Redistribution**	Diffusion des évènements	Kafka, Debezium, Schema Registry
4	**Stockages analytiques**	Persistance spécialisée	Snowflake, MongoDB, magasin de features
5	**Consommateurs**	Restitution et décision	Tableaux de bord, reporting interne, scoring de fraude
+1	**Transverse — conformité**	Sécurité et conformité	TLS, chiffrement, RLS, audit, rétention

Pourquoi la sixième n'est pas numérotée

Parce qu'elle ne s'intercale pas entre deux autres : elle traverse les cinq. Une conformité qui serait une couche pourrait être contournée en passant à côté. Transverse, elle ne peut pas l'être.

Appui — D5 §D5.2 (vue d'ensemble) · D1 §D1.6 (technologies)

Q2 Pourquoi trois bases de données et pas une seule ?

En une phrase. Parce que le système doit tenir trois régimes de temps incompatibles, et qu'aucun moteur ne tient les trois.

OLTP — PostgreSQL

- Schéma normalisé, intégrité ACID
- Un débit ne peut être ni perdu ni dupliqué : la cohérence forte n'est pas négociable ici
- Source de vérité : tout le reste en dérive

NoSQL — MongoDB

- Lecture par clé unique en moins de 10 ms, sur le chemin du paiement
- Documents sans jointure : on modélise selon les accès, pas selon le domaine
- Absorbe l'hétérogène : logs, sessions, features, feedbacks

OLAP — Snowflake

- Schéma en étoile, dimensions dénormalisées
- Agrégation sur des mois de données : l'inverse exact du besoin transactionnel
- Tolère un retard de quelques minutes

La contrepartie, assumée

Trois moteurs, c'est une cohérence à terme entre eux. C'est le prix payé, et il est documenté — voir la question suivante.

Appui — D1 §D1.2 · D5 §D5.2 et §D5.7.2 · D4 §D4.3 et §D4.4 · D3 §D3.2

Q3 Comment garantissez-vous la cohérence entre les systèmes ?

En une phrase. La cohérence forte n'est appliquée que là où elle est nécessaire ; ailleurs, elle est à terme, avec une latence cible chiffrée par flux.

Flux	Modèle	Latence cible	Justification
Paiement (OLTP)	**Forte, ACID**	Synchrone	Un débit ne peut être ni perdu ni dupliqué
Scoring de fraude	**Forte en lecture**	< 100 ms	Une feature périmée a un coût réel
OLTP → OLAP	À terme	< 5 min	Un tableau de bord tolère le délai
OLTP → NoSQL	À terme	< 30 s	Journaux et sessions sans criticité

La formulation exacte à employer

« Cohérence à terme entre les systèmes — jamais sur le chemin transactionnel. »
Dire seulement « cohérence à terme » laisse croire qu'un paiement pourrait se perdre. Les trois derniers mots ferment cette porte, et ils sont exacts : le paiement est ACID synchrone, et le scoring lit en cohérence forte.

Appui — D5 §D5.7.2 (modèles de cohérence) · D4 §D4.9

Q3 Et la réconciliation : comment détectez-vous une divergence ?

En une phrase. Un contrôle quotidien compare les comptes et les montants entre OLTP et OLAP ; c'est lui qui détecte une perte silencieuse de messages.

Prévenir — §D5.7.1

- Kafka livre au moins une fois : un message peut arriver deux fois
- Index unique sur transaction_id : la base rejette le doublon, pas l'application
- NoSQL : identifiants déterministes, pas d'ObjectId générés

Détecter — §D5.8

- Réconciliation quotidienne : comptes et montants doivent concorder entre OLTP et OLAP
- Complétude : aucun fait sans dimension correspondante
- Décalage des consommateurs et fraîcheur par table cible

Rattraper — §D5.7.3/4

- Pipeline unidirectionnel : la plupart des conflits sont éliminés par construction
- En cas de divergence, l'OLTP fait foi : le segment est rejoué depuis Kafka
- Au-delà de la rétention Kafka : rechargement par snapshot Debezium

La phrase du document

« La réconciliation est le contrôle le plus important : c'est lui qui détecte une perte silencieuse de messages. » — D5 §D5.8

Appui — D5 §D5.8 (supervision) · §D5.7.1, §D5.7.3, §D5.7.4

Q4 Et si Kafka tombe ?

En une phrase. Les paiements continuent — le chemin transactionnel ne traverse pas Kafka. Ce qui s'arrête, c'est la propagation vers les systèmes dérivés, et elle se rattrape par rejeu.

Ce qui continue

- L'application écrit dans l'OLTP en synchrone : la transaction est enregistrée
- Le scoring lit features et cache marchand dans MongoDB : la décision est rendue
- L'autorisation de paiement est donc servie normalement

Ce qui s'arrête

- L'alimentation de l'OLAP et du NoSQL : les tableaux de bord figent
- L'actualisation des features : elles vieillissent, la qualité du scoring se dégrade
- Les flux de retour vers l'OLTP : logs, incidents et scores ne sont plus écrits

Comment on rattrape

- Chaque consommateur reprend au dernier offset validé, sans perte
- Une table OLAP corrompue est reconstruite par rejeu sur la fenêtre concernée
- Au-delà de la rétention : rechargement depuis l'OLTP par snapshot Debezium

Ce que je concède

Pendant la panne, la journalisation d'audit qui remonte vers l'OLTP est suspendue : un trou de traçabilité, borné par la durée de l'incident et comblé au rattrapage.

Appui — D5 §D5.5.4, §D5.7.4 · D7 §D7.3.9.1 · D1 §D1.4.2

Q5 Pourquoi le reporting réglementaire ne passe-t-il pas par l'OLAP ?

En une phrase. Parce qu'il n'a ni le même consommateur, ni la même contrainte de délai, ni la même valeur probante — et qu'il ne doit pas dépendre d'un pipeline partagé.

	Reporting réglementaire	Reporting analytique
Consommateur	DPO, responsable conformité	Analyste risque, équipe GRC
Produit	Dépôts légaux, notification de violation, réponse à une demande RGPD	Tableaux de bord de tendance, corrélations, revues périodiques
Contrainte	Délai légal opposable — 72 h, 30 ou 45 jours	Aucune échéance légale, exploration libre
Fraîcheur	Nécessaire à l'instant du dépôt	Suffisante avec un décalage batch
Dépendance	Traçable à la source, isolé du pipeline partagé	Dépend du pipeline Kafka / Airflow / dbt
Source	OLTP	OLAP

Et pourquoi pas une connexion directe à la base transactionnelle ?

Parce que l'outil de reporting ne doit pas être exposé à l'OLTP. D'où un job d'extraction dédié : le chemin reste minimal, aussi proche de la source que possible, mais sans exposer la base.

Appui — D1 §D1.7 (reporting OLTP vs OLAP) · §D1.5.2 · D5 §D5.9.4

Q6 Le droit à l'effacement sur des journaux immuables : comment ?

En une phrase. Conserver les faits, effacer l'identité. La clé de substitution découple la mesure de la personne, ce qui permet de neutraliser l'une sans toucher aux autres.

Couche	Traitement
OLTP	Anonymisation de Customer ; les transactions sont conservées — valeur comptable et légale
OLAP	Anonymisation de DimCustomer ; FactTransaction reste intacte, les revenus agrégés demeurent exacts
NoSQL	Suppression effective, rendue possible par l'index customer_id présent dans chaque collection
Kafka	Message de suppression (tombstone) sur les topics compactés — d'où ce choix pour consent.events

L'avantage inattendu de la clé de substitution

Elle découple la mesure de l'identité : on neutralise ce qui se trouve derrière customer_key sans toucher aux faits qui la référencent. Le chiffre d'affaires d'un marchand reste juste après l'effacement d'un de ses clients.
Traçabilité : chaque demande est enregistrée dans DataSubjectRequest, avec due_at et fulfilled_at. L'écart entre les deux est l'indicateur audité — le rapport doit prouver le respect des délais, pas seulement l'existence de la procédure.

Appui — D5 §D5.9.3 · D6 §D6.5 · D3 §D3.5.1

Q7 Le scoring de fraude est-il réentraîné automatiquement ?

En une phrase. Oui, mensuellement par principe — non par précaution, mais parce que la fraude est un domaine adversarial où un modèle figé perd mécaniquement en efficacité.

Déclencheur	Action
Périodique (mensuel)	Réentraînement systématique sur données récentes
Dérive détectée	Réentraînement anticipé
Dégradation métier	Investigation, puis retour arrière ou réentraînement
Nouveau schéma de fraude	Ajout de features, puis réentraînement

La difficulté structurelle : le label différé

On ne sait pas immédiatement si une transaction était frauduleuse : le label vient de la rétro-facturation, plusieurs semaines plus tard. Un modèle peut donc se dégrader pendant des semaines avant que la métrique de qualité ne le révèle.
Compensation : des indicateurs avancés qui ne dépendent pas du label — distribution des scores, taux de blocage, taux d'authentification renforcée. Leur dérive alerte avant que les rétro-facturations ne confirment le problème.

Appui — D7 §D7.3.9 (monitoring et actualisation)

Q8 Quelle volumétrie ? Quel dimensionnement ?

En une phrase. Le dossier n'en chiffre aucune. C'est une limite déclarée dans D0, pas un oubli — et elle ne change pas l'architecture, seulement son dimensionnement.

Ce qui est explicitement hors périmètre

- Aucun chiffre de volumétrie, de débit, ni de taille de cluster
- Scalabilité horizontale de l'OLTP : SGBD centralisé, pas de partitionnement, pas de sharding, pas de cache
- Aucune vérification par une implémentation : ce sont des propositions de conception

Ce qui est malgré tout dimensionné

- Des latences cibles par flux : < 10 ms, < 100 ms, < 30 s, < 5 min
- Des clés de sharding NoSQL choisies collection par collection, sur le motif d'accès dominant
- Un partitionnement OLAP par date_key et un stockage orienté colonnes

Ce que je répondrais

Les choix sont argumentés par les motifs d'accès et par les contraintes de latence, pas par une capacité cible. Chiffrer la volumétrie est l'étape suivante : elle ferait bouger le dimensionnement, pas la structure.

Appui — D0 §0.4.3 (limites) · D4 §D4.7 · D5 §D5.7.2 · D3 §D3.5.3